UNIVERSIDAD DE LOS LAGOS

# Capacitación - Estadística Aplicada

Sesión 1 – 12 diciembre 2024

**Pablo Herrera Gálvez / paherreragalvez@gmail.com**

# Capacitación - Estadística Aplicada

- Tipos de variables.
- Estadística descriptiva.
- Asociación entre variables (correlaciones).
- Normalidad y funciones de distribución.
- Test de Hipótesis.

UNIVERSIDAD DE LOS LAGOS

# Capacitación - Estadística Aplicada

- **Tipos de variables.**
- Estadística descriptiva.
- Asociación entre variables (correlaciones).
- Normalidad y funciones de distribución.
- Test de Hipótesis.

UNIVERSIDAD DE LOS LAGOS

# Tipos de variable

- Variables categóricas.
  - Nominales (y binarias).
  - Ordinales.
- Variables discretas.
- Variables continuas.

# Tipos de variable

**Variables categóricas:**

- Nominales: Son las que poseen menos información. Permiten crear categorías entre la población, pero no están asociadas a un orden. *Ejemplos: estado civil, equipo favorito, país de origen*.
  - Binarias: Cuando solo existen dos categorías, hablamos de una variable binaria o dicotómica. *Ejemplos: sexo, aprobado o reprobado, estar empleado o no, ser beneficiario de un programa o no*.
- Ordinales: A diferencia de las variables nominales, estas variables permiten ordenar. Las distancias entre cada nivel no son interpretables. Ejemplos: nivel educacional alcanzado, tramos de ingreso, nivel de satisfacción con un servicio.

# Tipos de variable

**Variables discretas:**

- Aquellas que solo pueden tomar valores específicos y contables, como números enteros. Entre un valor y otro, no hay valores posibles.
- *Ejemplos: cantidad de hijos, libros en un estante, cursos aprobados.*

# Tipos de variable

**Variables continuas:**

- Aquellas que pueden tomar cualquier valor dentro de un rango, incluyendo fracciones y decimales.
- *Ejemplos: peso, altura o temperatura*.

# Capacitación - Estadística Aplicada

- Tipos de variables.
- **Estadística descriptiva.**
- Asociación entre variables (correlaciones).
- Normalidad y funciones de distribución.
- Test de Hipótesis.



UNIVERSIDAD DE LOS LAGOS

# Estadística descriptiva

- Estadísticos relevantes.
  - Medidas de tendencia central: media, mediana y moda.
  - Medidas de posición o distribución: cuantiles (e.g. cuartiles, quintiles, deciles, percentiles).
  - Medidas de dispersión: varianza y desviación estándar.
- Tablas de frecuencia.
- Visualizaciones de datos.

# Estadística descriptiva

**Estadísticos relevantes** – medidas de tendencia central:

- **Media**. El centro de gravedad de la distribución (el promedio).

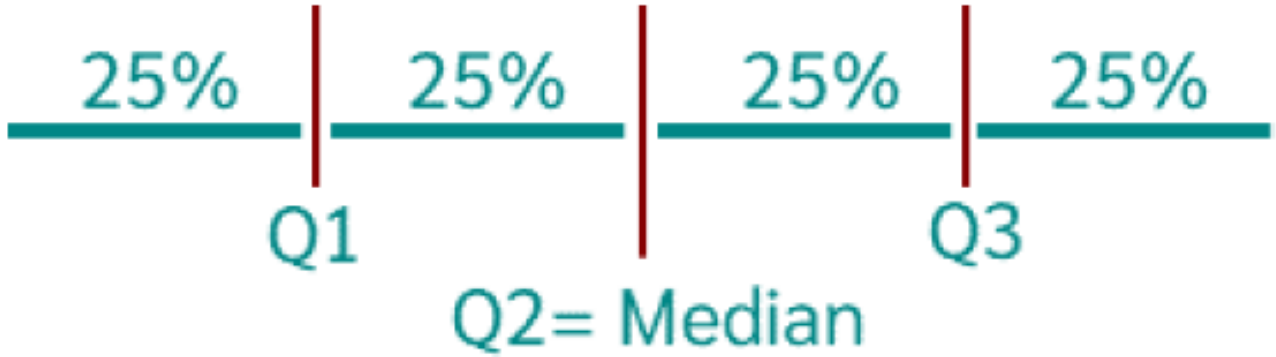
$$\bar{x} = \frac{x_1 + x_2 + x_3 + \ldots + x_n}{n} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

- **Mediana**. Si los valores que toma una variable son ordenados de menor a mayor, el valor del medio es la mediana. Divide la distribución en dos mitades iguales (también es el percentil 50).
- **Moda**. Es el valor más común en la muestra o población.

# Estadística descriptiva

**Estadísticos relevantes** – medidas de posición o distribución:

- Cuantiles (e.g. cuartiles, quintiles, deciles, percentiles).



# Estadística descriptiva

**Estadísticos relevantes –** medidas de dispersión:

- **Varianza**. Describe el **promedio del cuadrado de las distancias** con respecto a la media.
- **Desviación estándar**. Es un cálculo que facilita la interpretación de la varianza. Es la raíz cuadrada de la varianza.
  - Video: https://www.youtube.com/watch?v=FQDXUlem8ro
- Ambas son medidas de dispersion, pero la desviación estándar facilita la interpretación.
  - Supongamos que estudiamos la dispersión de los ingresos de la población. La varianza estará expresada en [pesos chilenos]$^2$ y la desviación estándar estará expresada simplemente en [pesos chilenos].

# Estadística descriptiva

**Estadísticos relevantes –** medidas de dispersión:

- **Varianza (poblacional y muestral).**

$$\sigma^2 = \frac{\sum_{i=0}^{n}(x_i - \mu)^2}{n}$$

$$s^2 = \frac{\sum_{i=0}^{n}(x_i - \bar{x})^2}{n-1}$$

- **Desv. estándar (poblacional y muestral).**

$$\sigma = \sqrt{\frac{\sum_{i=0}^{n}(x_i - \mu)^2}{n}}$$

$$s = \sqrt{\frac{\sum_{i=0}^{n}(x_i - \bar{x})^2}{n-1}}$$

# Estadística descriptiva

## Tablas de frecuencia.

Tabla 1. Frecuencia según nivel de dependencia.

| Nivel de dependencia | Población | % | % acumulado |
|---|---|---|---|
| Sin dependencia | 13.856.983 | 90,2 | 90,2 |
| Dependencia leve | 529.274 | 3,4 | 93,7 |
| Dependencia moderada | 549.424 | 3,6 | 97,3 |
| Dependencia severa | 420.279 | 2,7 | 100,0 |
| **Total** | **15.355.960** | **100** | |

# Estadística descriptiva

## Tablas de estadística descriptiva.

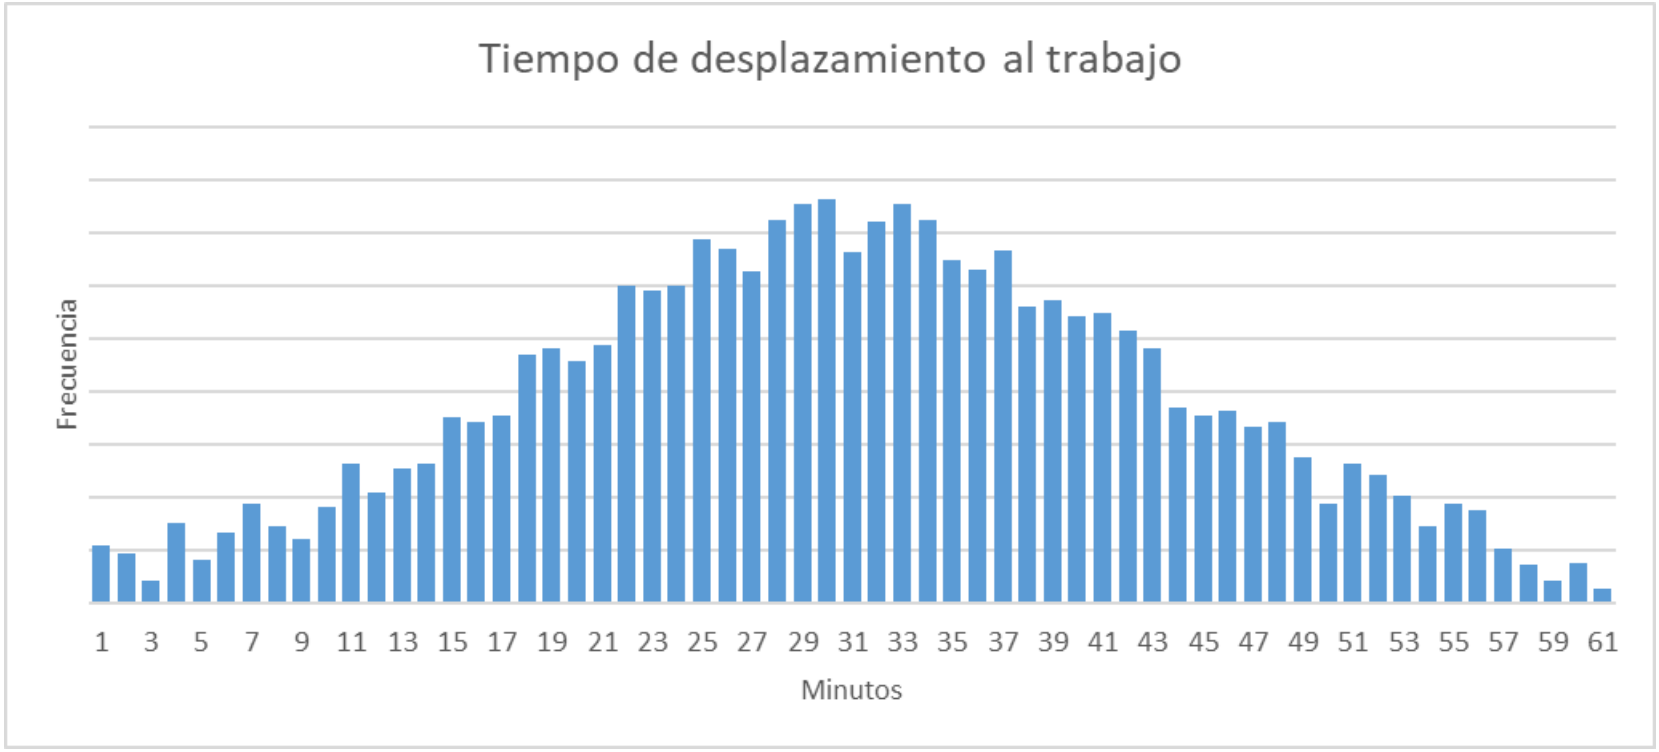
Tabla 2. Estadística descriptiva ingresos laborales población trabajadora, según quintil.

| Quintil | Población | % | Media | Percentil 25 | Mediana | Percentil 75 |
|---|---|---|---|---|---|---|
| 1 | 1.643.096 | 20,1 | 109.618 | 50.000 | 103.750 | 170.000 |
| 2 | 1.797.253 | 21,9 | 272.626 | 260.000 | 272.000 | 293.613 |
| 3 | 1.475.474 | 18,0 | 359.920 | 332.000 | 354.417 | 400.000 |
| 4 | 1.719.354 | 21,0 | 535.460 | 465.833 | 507.500 | 600.000 |
| 5 | 1.557.537 | 19,0 | 1.533.580 | 840.417 | 1.080.000 | 1.655.000 |
| **Total** | **8.192.714** | **100** | **550.537** | **252.500** | **350.000** | **600.000** |

# Estadística descriptiva

**Visualizaciones** – distribución:

- *Histograma 1*.



# Estadística descriptiva

**Visualizaciones** – distribución:

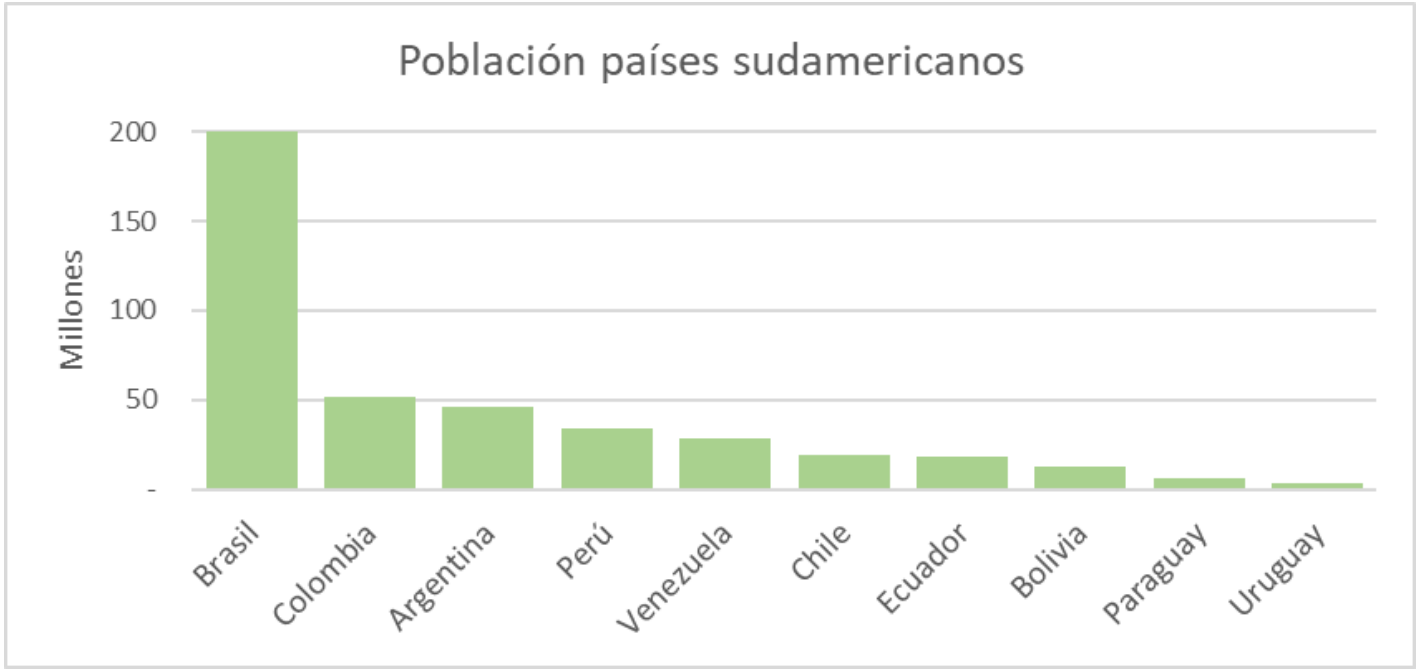
- *Histograma 2 (agrupado)*.



# Estadística descriptiva

**Visualizaciones** – comparación de una variable numérica (continua o discreta), según grupos:

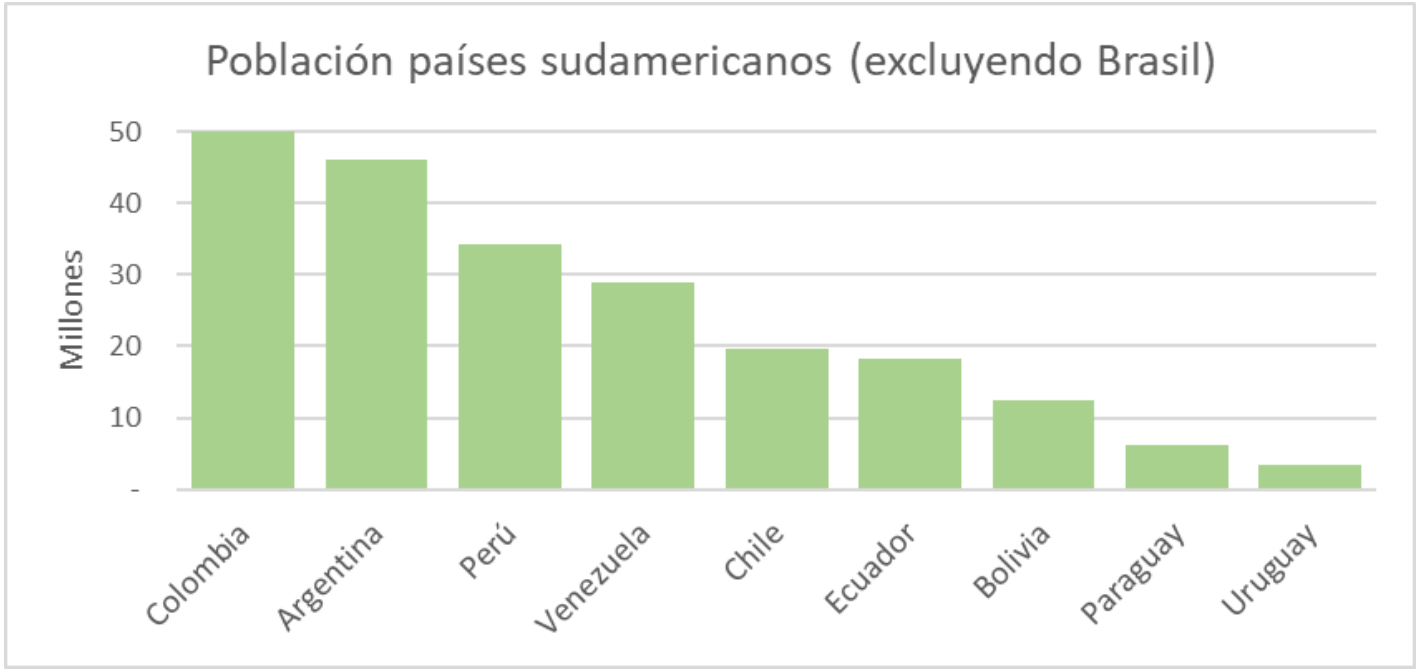
- *Gráfico de columnas*.



# Estadística descriptiva

**Visualizaciones** – comparación de una variable numérica (continua o discreta), según grupos:

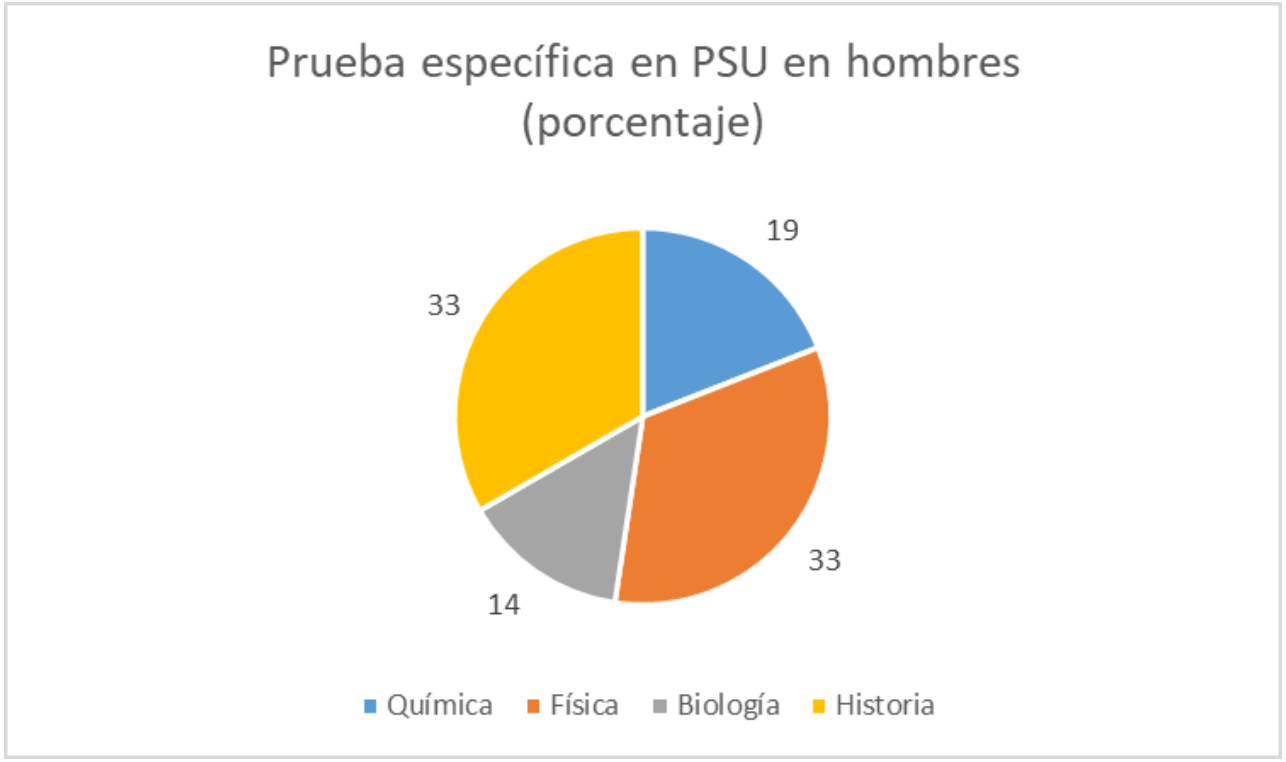
- *Gráfico de columnas*.



# Estadística descriptiva

**Visualizaciones** – proporción:

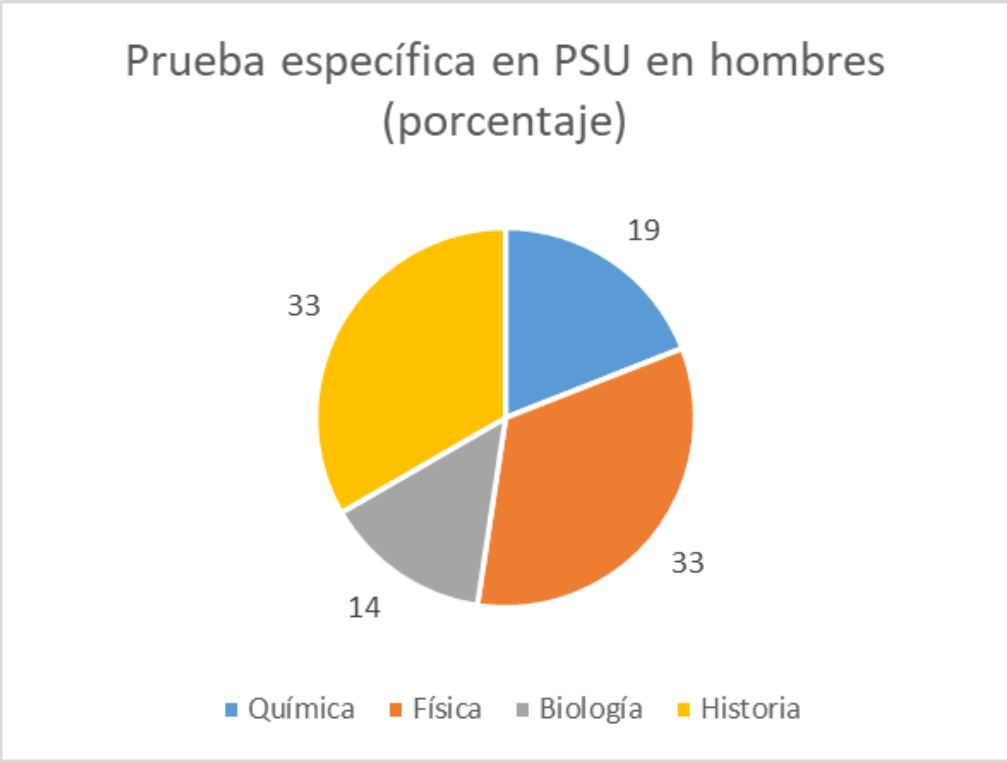
- *Gráfico de torta*.

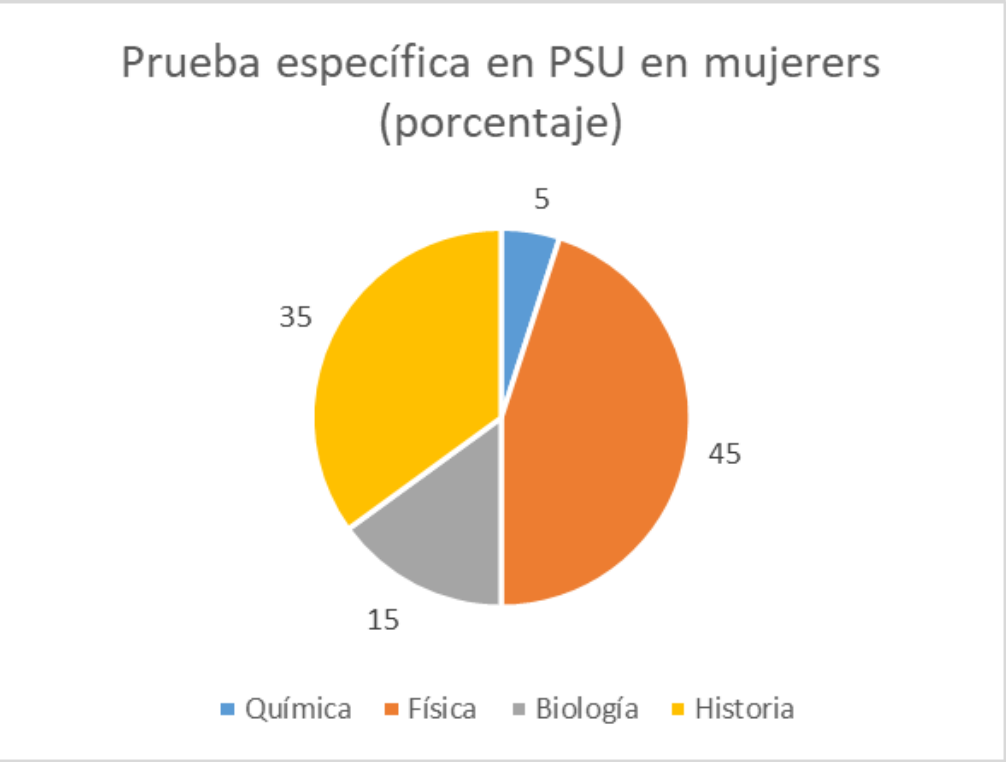


# Estadística descriptiva

**Visualizaciones** – proporciones (comparación):

- *Gráfico de torta*.

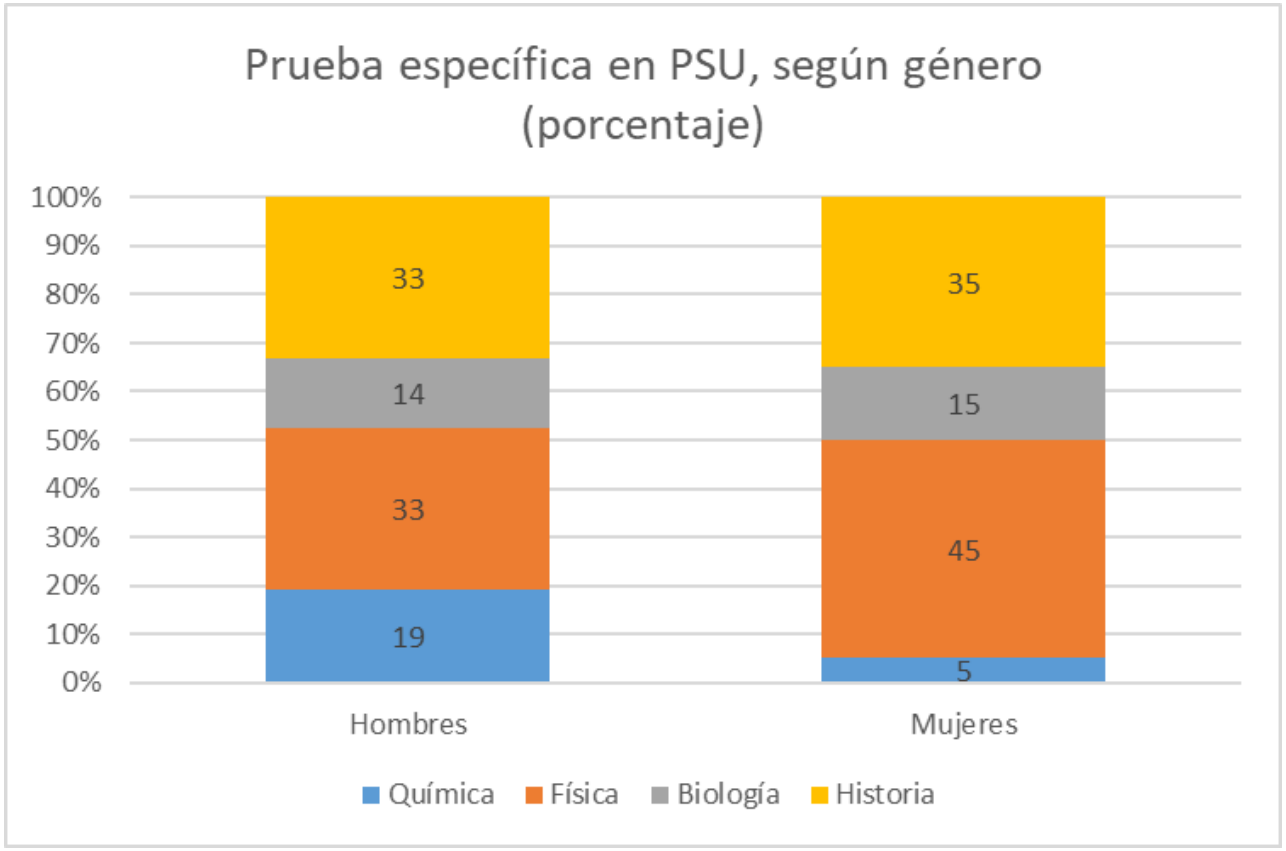


# Estadística descriptiva

**Visualizaciones** – proporciones (comparación):

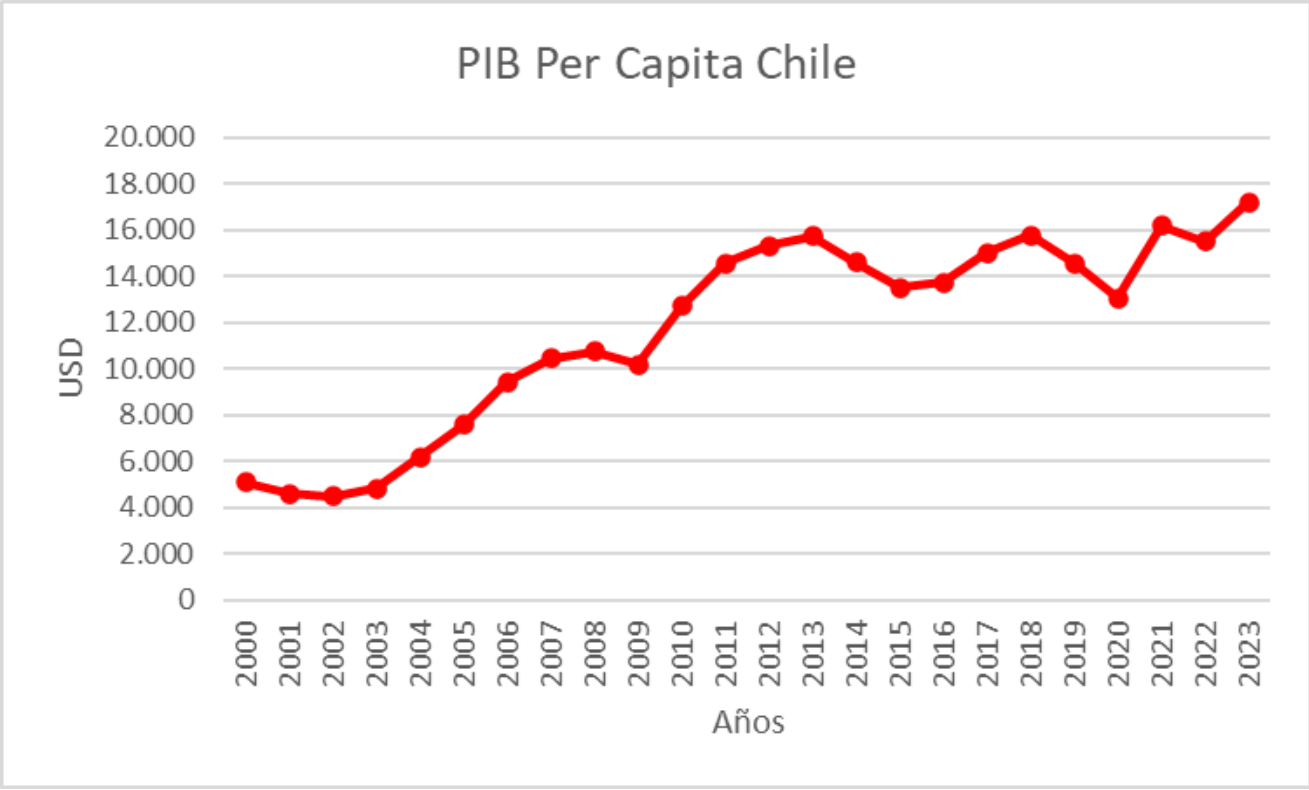
- *Gráfico de barras apiladas al 100%*.



# Estadística descriptiva

**Visualizaciones** – evolución en el tiempo.

- *Gráfico de líneas*.



# Capacitación - Estadística Aplicada

- Tipos de variables.
- Estadística descriptiva.
- **Asociación entre variables (correlaciones).**
- Normalidad y funciones de distribución.
- Test de Hipótesis.

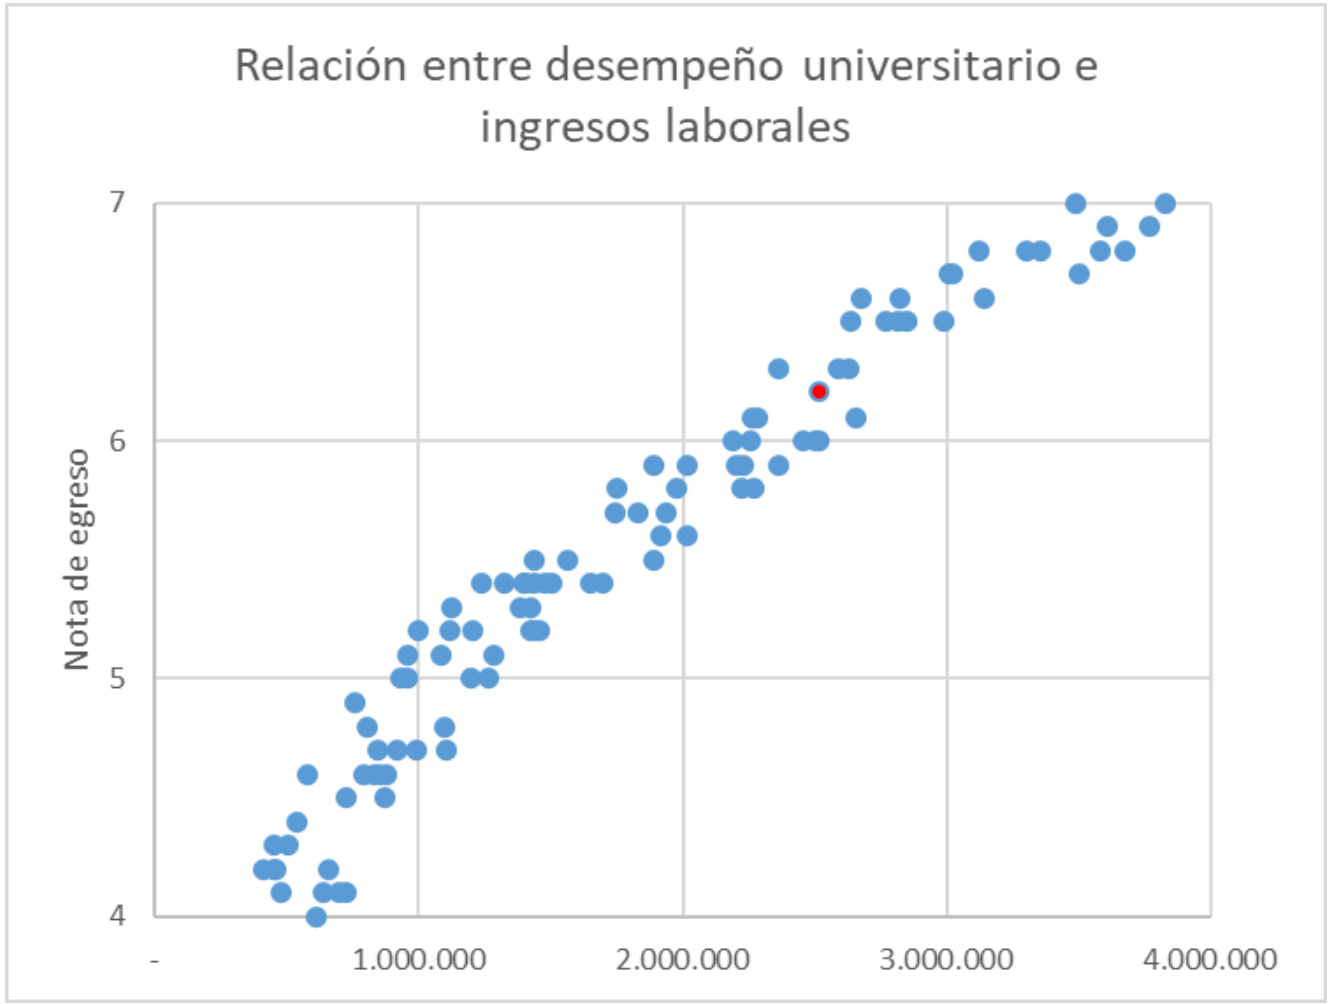


UNIVERSIDAD DE LOS LAGOS

# Asociación entre variables

- Covarianza.
- Coeficiente de correlación de Pearson.
- Coeficiente de correlación de Spearman.
- Coeficiente de correlación Tau de Kendall.

# Asociación entre variables



# Asociación entre variables

Covarianza.

$$Cov(x,y) = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{N-1}$$

- Trabaja con variables numéricas (continuas o discretas).
- Estudia si existe variación conjunta entre las variables. Medida de asociación lineal.
- Supone normalidad de las variables estudiadas.
- Interpretación:
  - Cov positiva → relación lineal positiva entre las variables,
  - Cov negativa → relación negativa entre ellas,
  - Cov cercana a 0 → poca o nula relación entre las variables.
- Toma valores entre el infinito positivo y negativo.
- Dificulta la comparación de covarianzas entre distintos pares de variables.

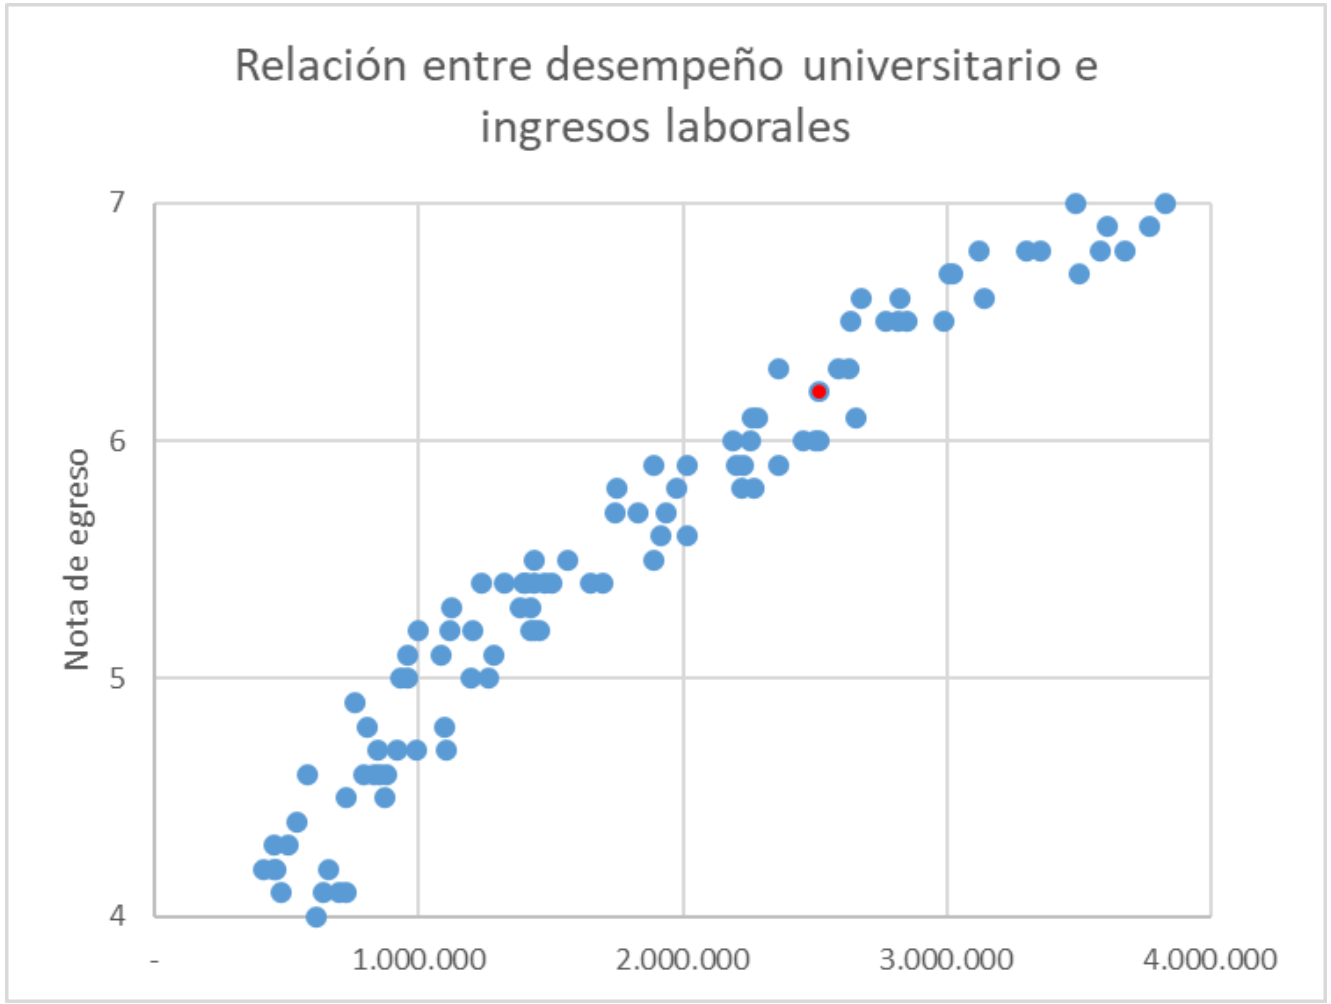
# Asociación entre variables

Coef. de Correlación de Pearson.

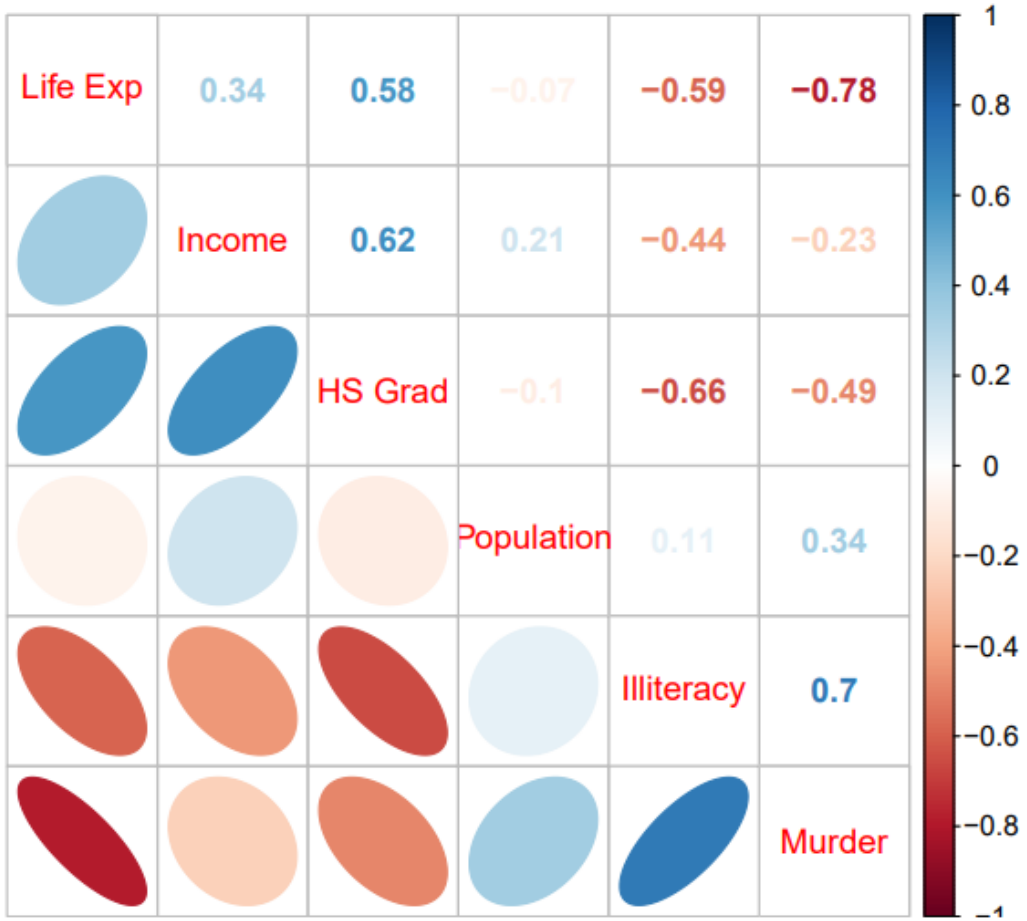
$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \cdot \sum_{i=1}^{n}(y_i - \bar{y})^2}}$$

- Normaliza valores de la covarianza.
- También supone normalidad de las variables estudiadas.
- Toma valores entre -1 y +1. Haciendo más intuitivo el resultado y permitiendo la comparación de correlaciones con mayor facilidad.
- Interpretación: magnitud y signo.
- **IMPORTANTE:** Una correlación fuerte (+ o -), no implica que exista causalidad.
- Video: https://www.youtube.com/watch?v=VF7SLPx1NnY

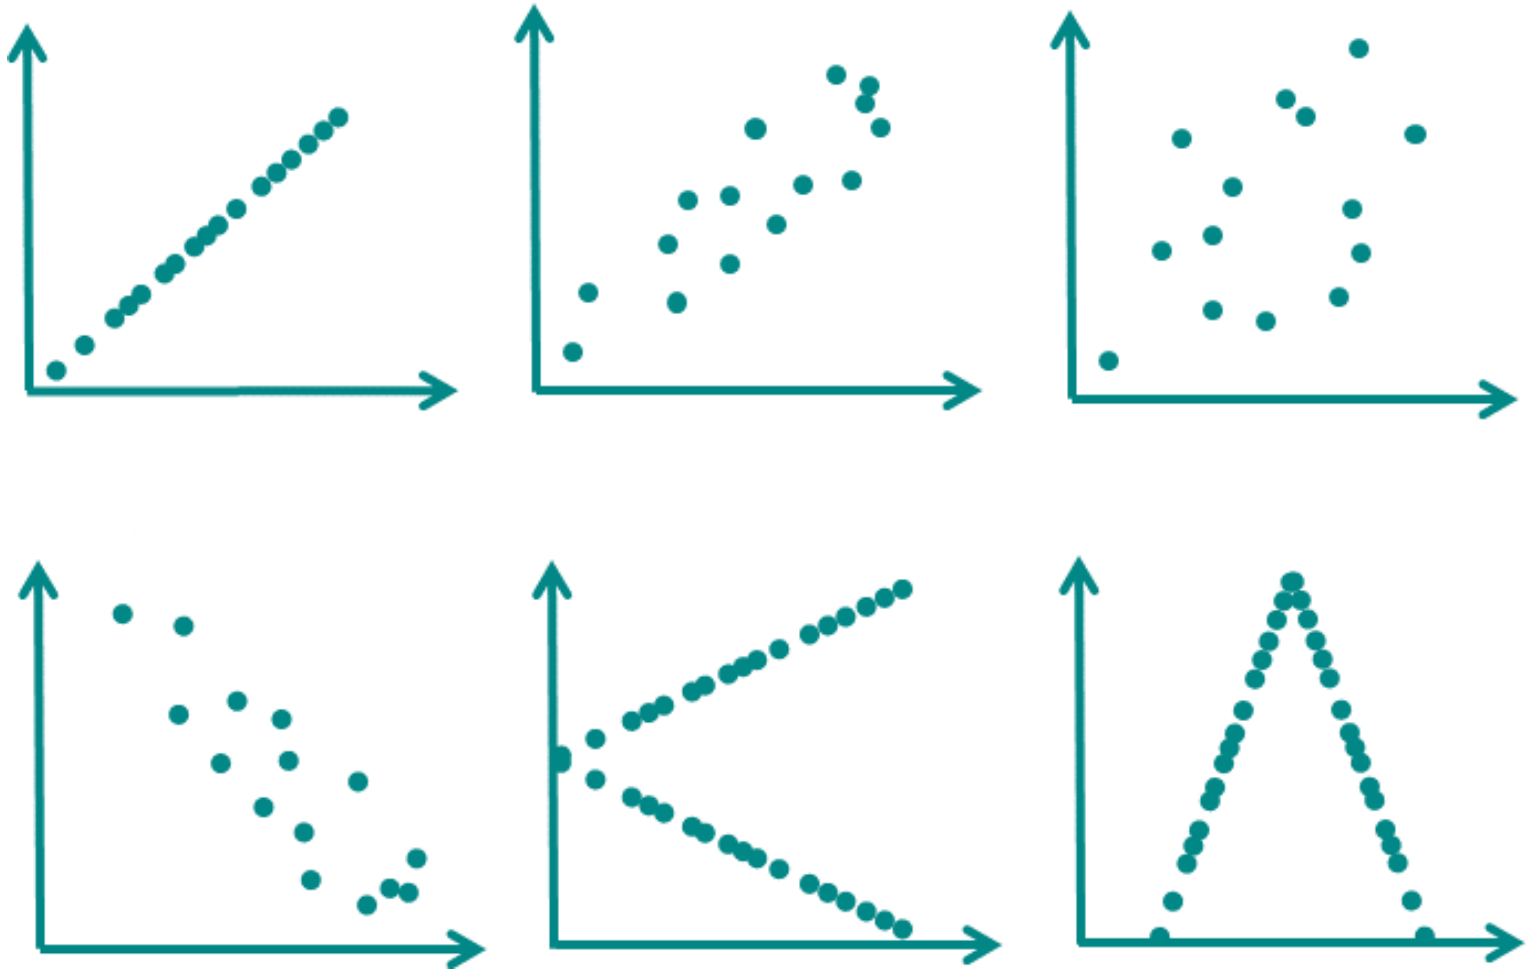
# Asociación entre variables



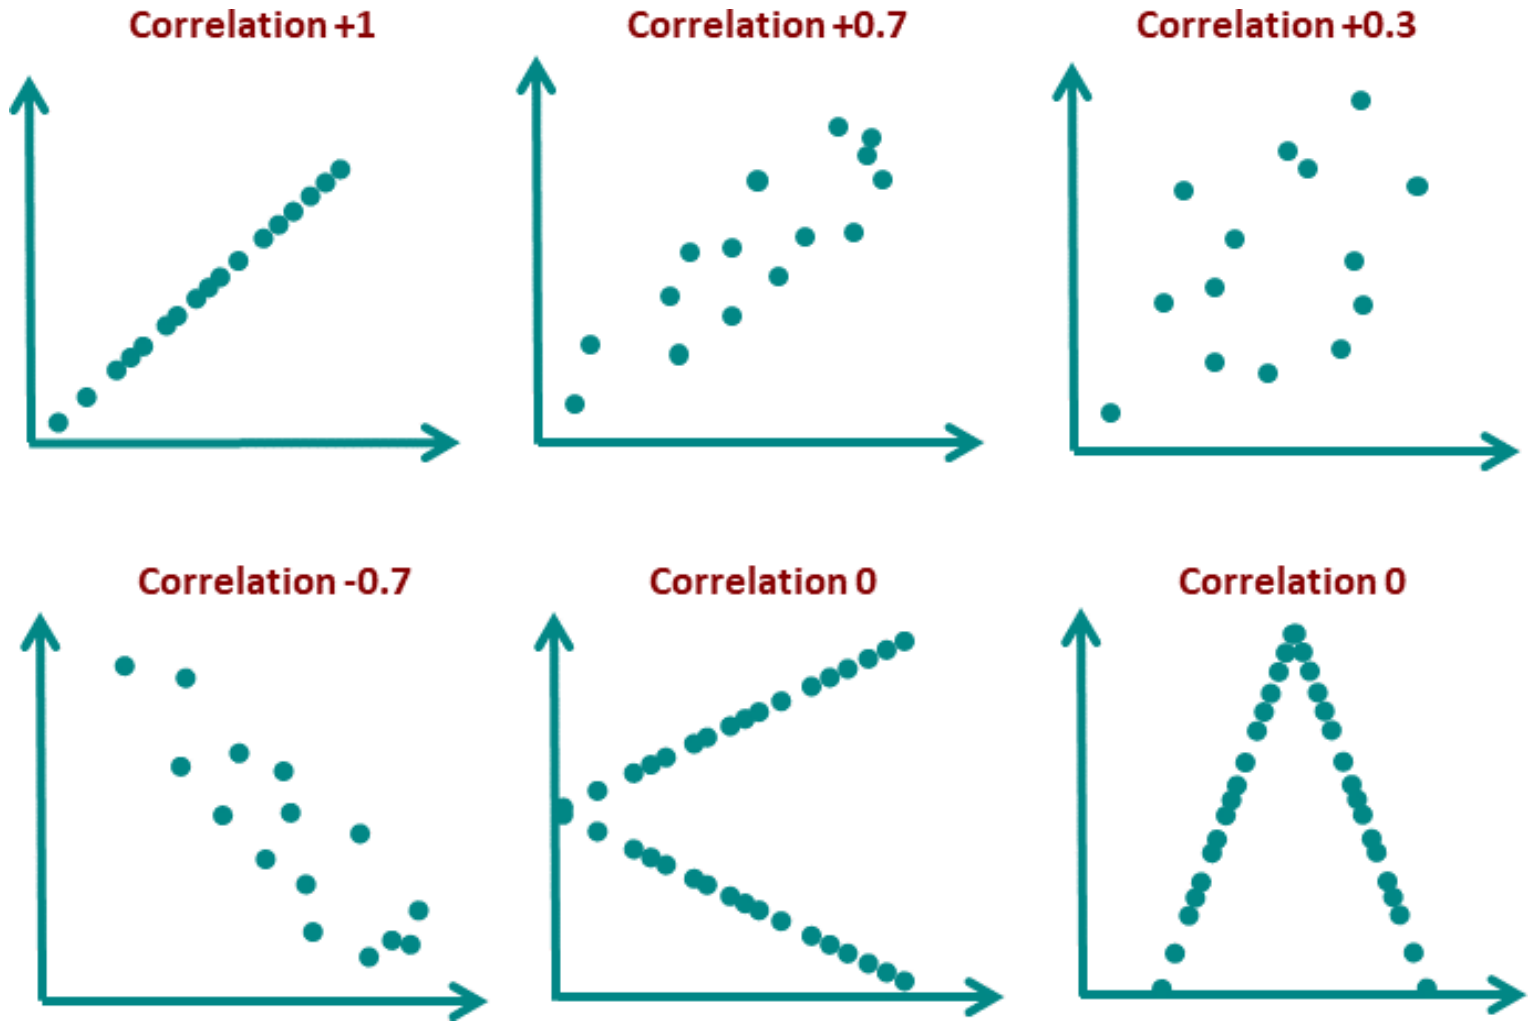
# Asociación entre variables



# Asociación entre variables



# Asociación entre variables



# Asociación entre variables

¿Qué pasa cuando las variables que estudiamos no se distribuyen como una normal o no son variables continuas?

- Coeficiente de correlación de Spearman.
  - Cuando no se cumple con la normalidad.
  - Variables categóricas.
  - Video: https://www.youtube.com/watch?v=bTr48I8vQd4
- Coeficiente de correlación Tau de Kendall.
  - Cuando además de no cumplirse la normalidad, se cuenta con una muestra pequeña.
  - Video: https://www.youtube.com/watch?v=3vUdmd1jHdA

# Asociación entre variables

- Covarianza.
- Coeficiente de correlación de Pearson.
  - Variables deben distribuir normalmente.
  - Variables deben ser continuas.
- Coeficiente de correlación de Spearman.
  - Cuando no se cumple con la normalidad.
  - Variables categóricas.
- Coeficiente de correlación Tau de Kendall.
  - Cuando además de no cumplirse la normalidad se cuenta con una muestra pequeña.

# Capacitación - Estadística Aplicada

- Tipos de variables.
- Estadística descriptiva.
- Asociación entre variables (correlaciones).
- **Normalidad y funciones de distribución.**
- Test de Hipótesis.



UNIVERSIDAD DE LOS LAGOS

# Normalidad y funciones de distribución

- **Función de distribución de probabilidad**, se utiliza para describir la probabilidad de ocurrencia de un suceso.
  - En variables discretas, la fdp es la lista de todos los posibles valores que la variable puede tomar y la probabilidad asociada a cada uno. Estas probabilidades suman 1 (o 100%).
  - En variables continuas, es difícil que la variable tome valores exactos (dado que es continua). Por lo tanto se habla de rangos (menor que, mayor que, dentro de un rango).

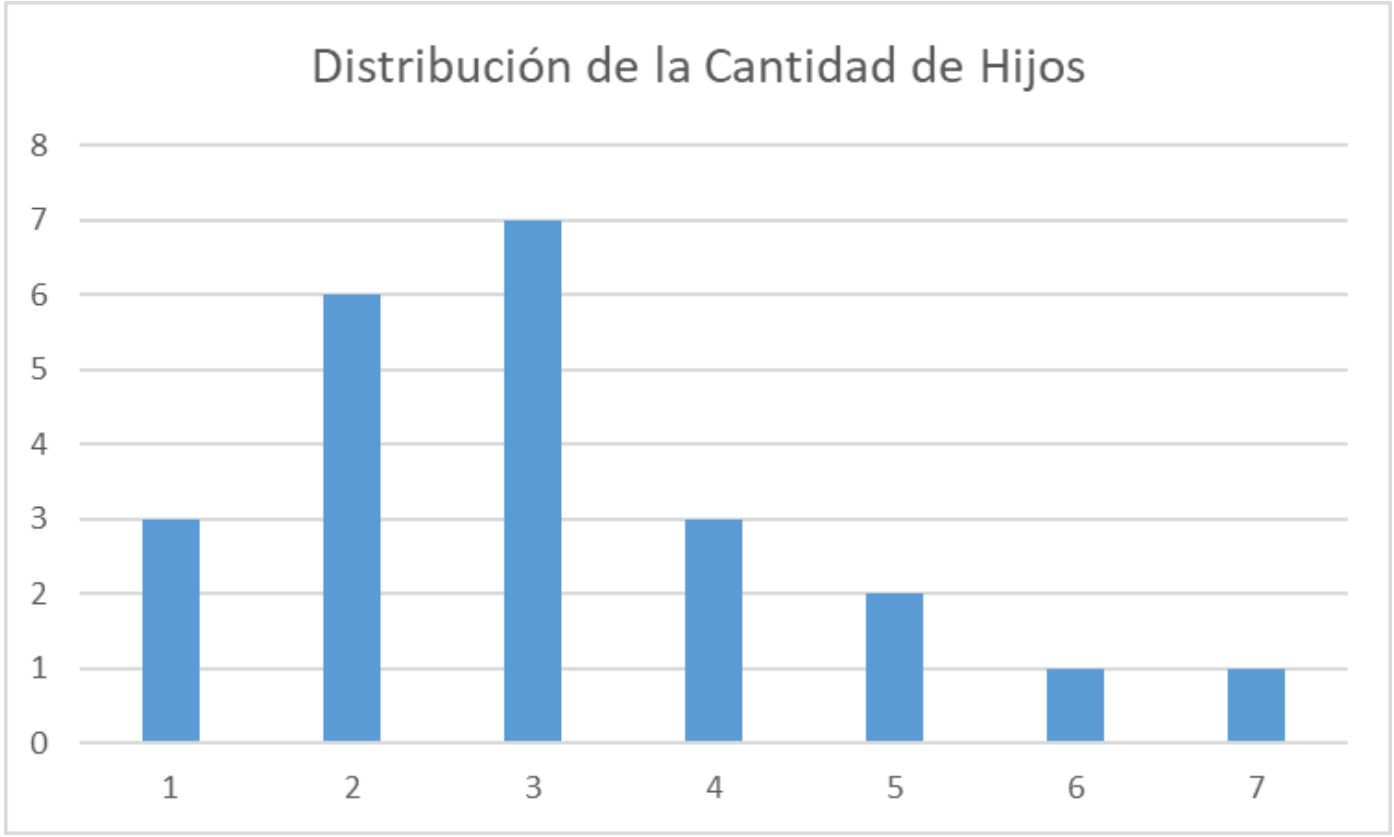
# Normalidad y funciones de distribución

| Número de hijos | Frecuencia | Probabilidad | Prob. Acum. |
|---|---|---|---|
| 1 | 3 | 0,13 | 0,13 |
| 2 | 6 | 0,26 | 0,39 |
| 3 | 7 | 0,30 | 0,70 |
| 4 | 3 | 0,13 | 0,83 |
| 5 | 2 | 0,09 | 0,91 |
| 6 | 1 | 0,04 | 0,96 |
| 7 | 1 | 0,04 | 1,00 |
| **Total** | **23** | **1** | |



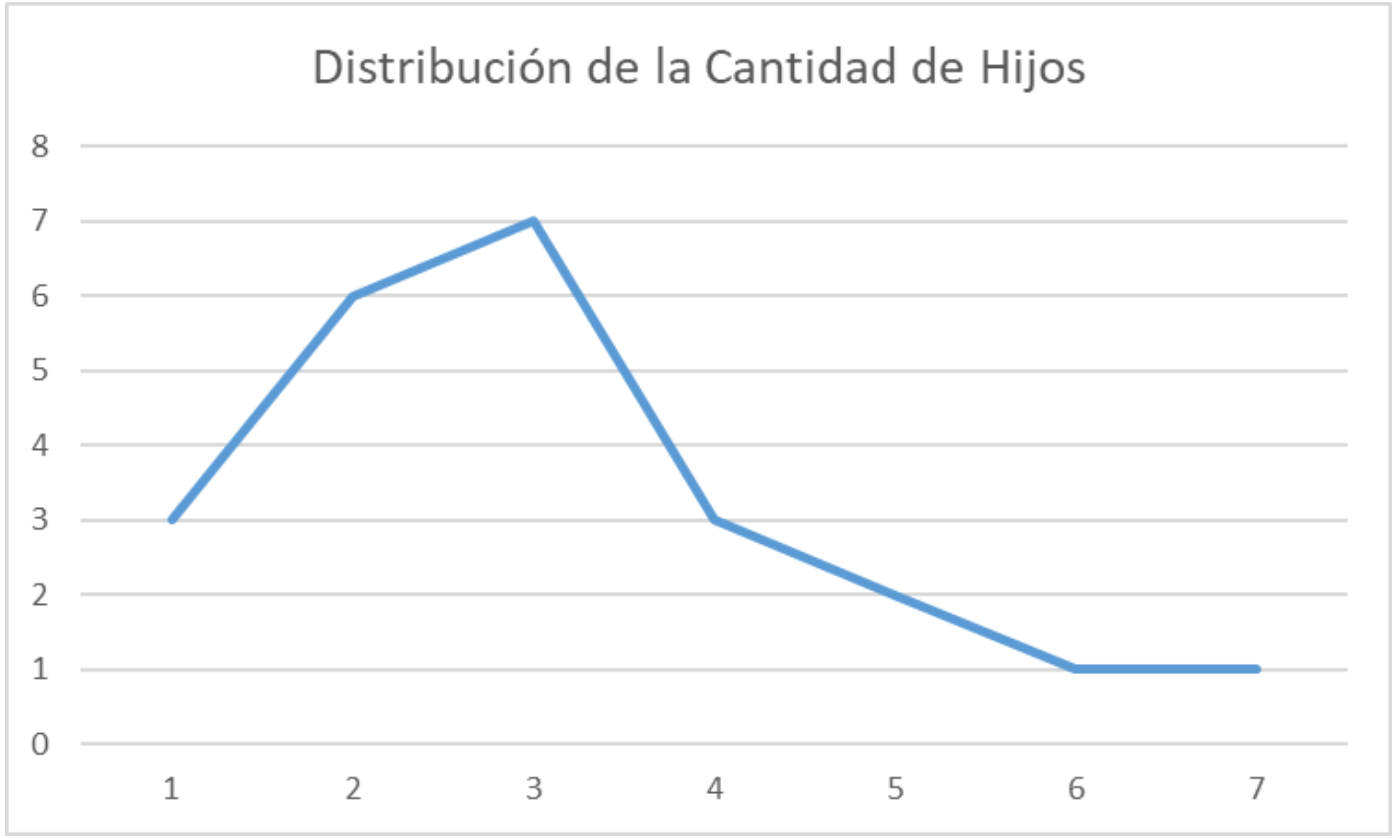
# Normalidad y funciones de distribución

| Número de hijos | Frecuencia | Probabilidad | Prob. Acum. |
|---|---|---|---|
| 1 | 3 | 0,13 | 0,13 |
| 2 | 6 | 0,26 | 0,39 |
| 3 | 7 | 0,30 | 0,70 |
| 4 | 3 | 0,13 | 0,83 |
| 5 | 2 | 0,09 | 0,91 |
| 6 | 1 | 0,04 | 0,96 |
| 7 | 1 | 0,04 | 1,00 |
| **Total** | **23** | **1** | |

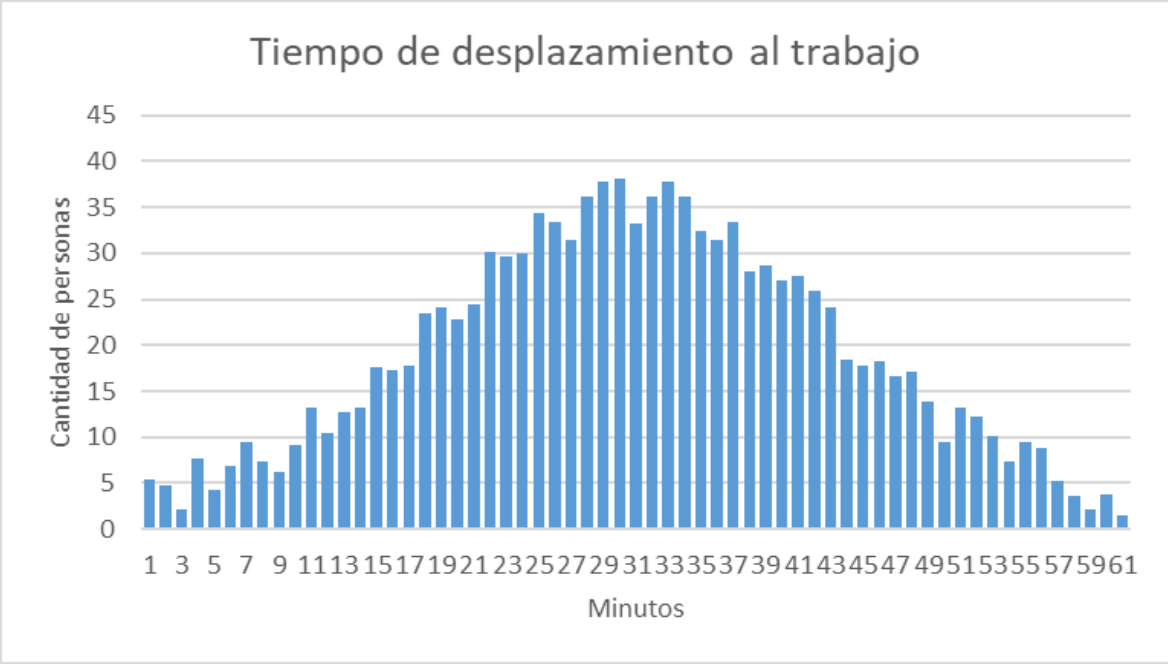


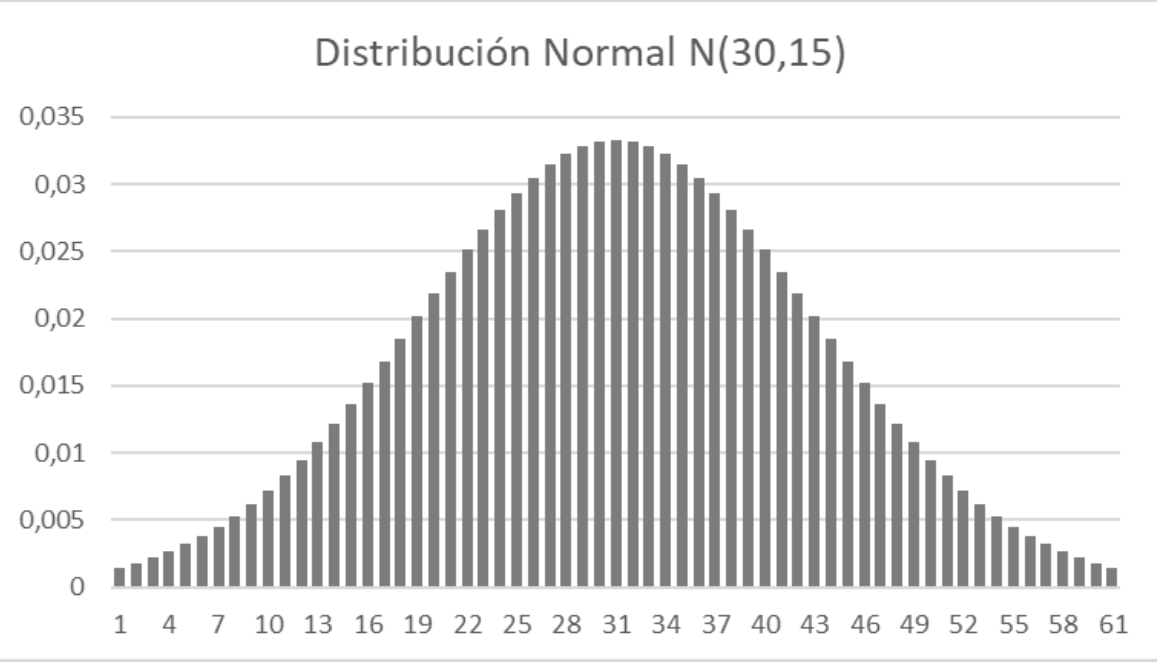
# Normalidad y funciones de distribución

| Número de hijos | Frecuencia | Probabilidad | Prob. Acum. |
|---|---|---|---|
| 1 | 3 | 0,13 | 0,13 |
| 2 | 6 | 0,26 | 0,39 |
| 3 | 7 | 0,30 | 0,70 |
| 4 | 3 | 0,13 | 0,83 |
| 5 | 2 | 0,09 | 0,91 |
| 6 | 1 | 0,04 | 0,96 |
| 7 | 1 | 0,04 | 1,00 |
| **Total** | **23** | **1** | |



# Normalidad y funciones de distribución



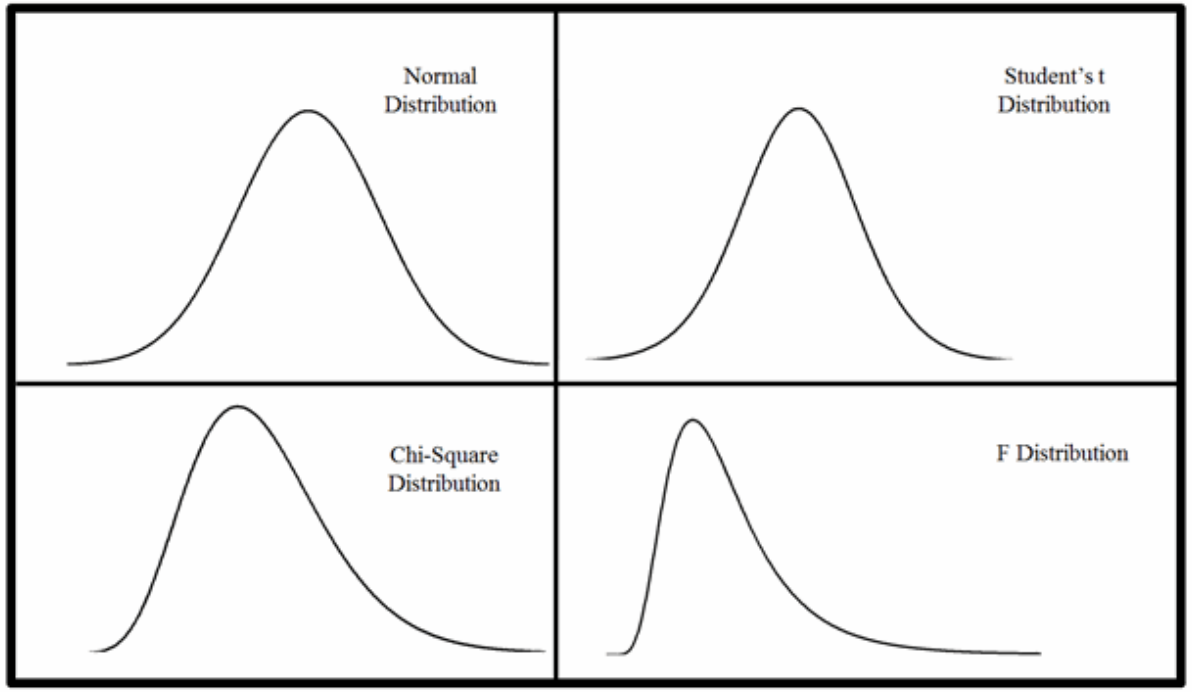



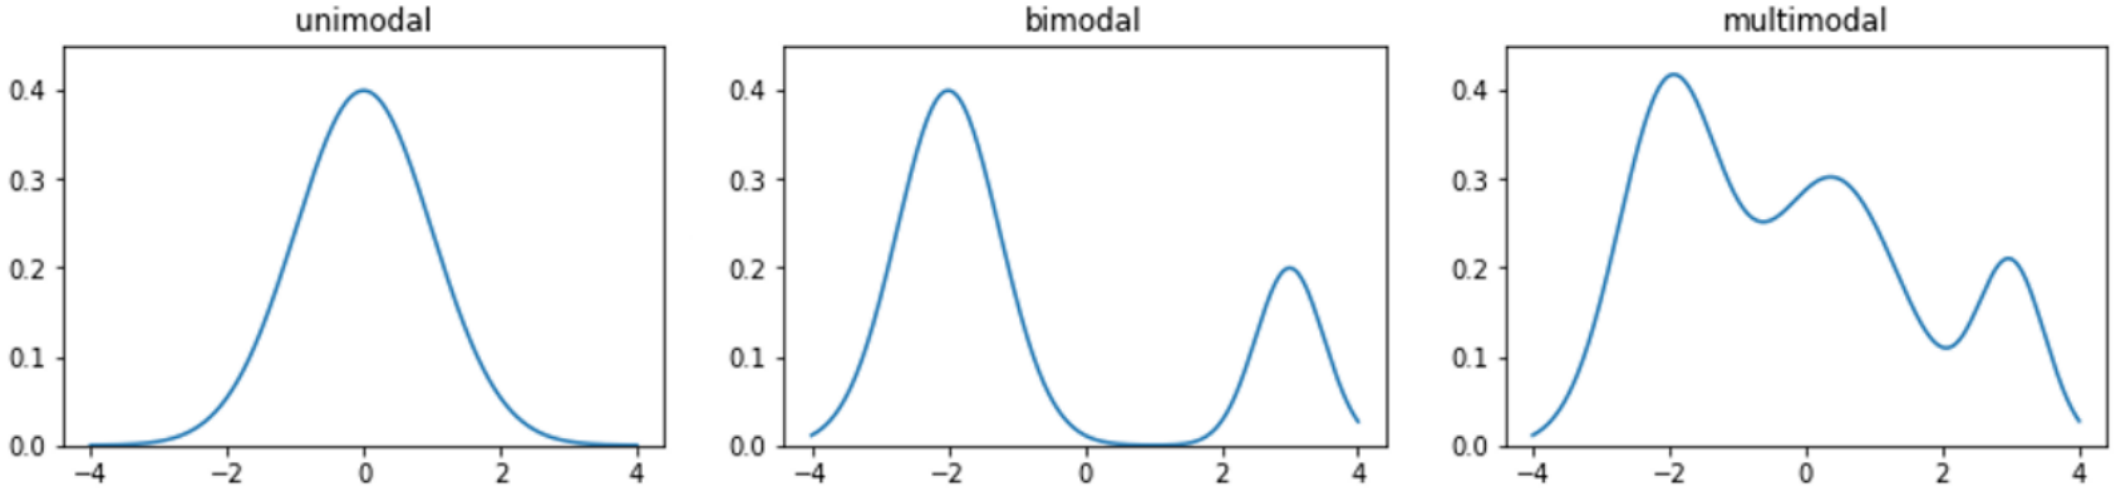
# Normalidad y funciones de distribución

- La distribución normal es una de las múltiples distribuciones que existen.
- Media: La distribución normal está centrada en su media (o promedio). Es una distribución simétrica.
- Desviación estándar: A mayor dispersión, menos probabilidad concentrada en el centro (y más en las colas).
- Existen maneras de testear normalidad:
  - Test de Kolmogorov-Smirnov, Test de Shapiro-Wilk, y el Test de Anderson Darling. Video en inglés: https://www.youtube.com/watch?v=AVketBmpUTE
  - Análisis gráfico.

# Normalidad

- También existen otras Funciones de distribución.



# Capacitación - Estadística Aplicada

- Tipos de variables.
- Estadística descriptiva.
- Asociación entre variables (correlaciones).
- Normalidad.
- **Test de Hipótesis.**



UNIVERSIDAD DE LOS LAGOS

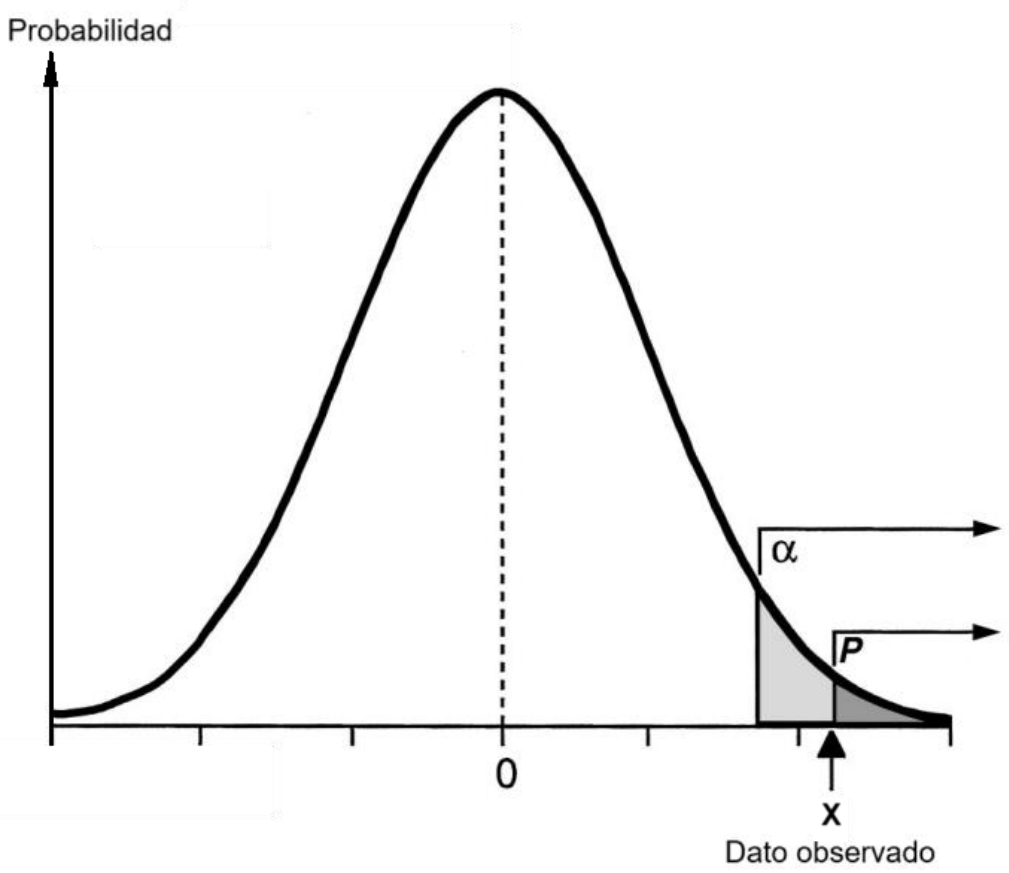
# Test de Hipótesis

- Hipótesis nula ($H_0$) y alternativa ($H_1$).
- Preguntas sí o no.
- Buscamos responder estas preguntas en base a la evidencia.
- P-Value.
  - Dado que trabajamos con muestras, el valor muestral (nuestra estimación) rara vez es exactamente igual al valor real (valor poblacional).
  - Una muestra no nos permite ser concluyentes, sin embargo podemos hacer
  - Representa cuál es la probabilidad de que hubiésemos obtenido un resultado tan distinto a la hipótesis nula ($H_0$), como lo hemos hecho.

# Test de Hipótesis

P-value.

- Un p-value pequeño quiere decir que es muy improbable que la H0 se cumpla para la muestra.
- Rechazamos la hipótesis nula, aceptando la hipótesis alternativa.
- Si el p-value es grande, no temenos evidencia suficiente para rechazar la hipótesis nula.



# Test de Hipótesis

- Nivel de significancia (α). Valores comúnmente utilizados son 0.1, 0.05 y 0.01 (10%, 5% y 1% respectivamente).
- Nivel de confianza (1-α). Valores comúnmente utilizados son 0.90, 0.95 y 0.99 (90%, 95 y 99% respectivamente).
- Intervalo de confianza: Aquellos valores para los cuales no rechazaría la hipótesis nula.
- Pasos para conducir un test de hipótesis:
  - Definir las hipótesis nula y alternativa ($H_0$ y $H_1$).
  - Aplicar el test.
  - Comparar el p-value con el nivel de significancia definido.

# Test de Hipótesis

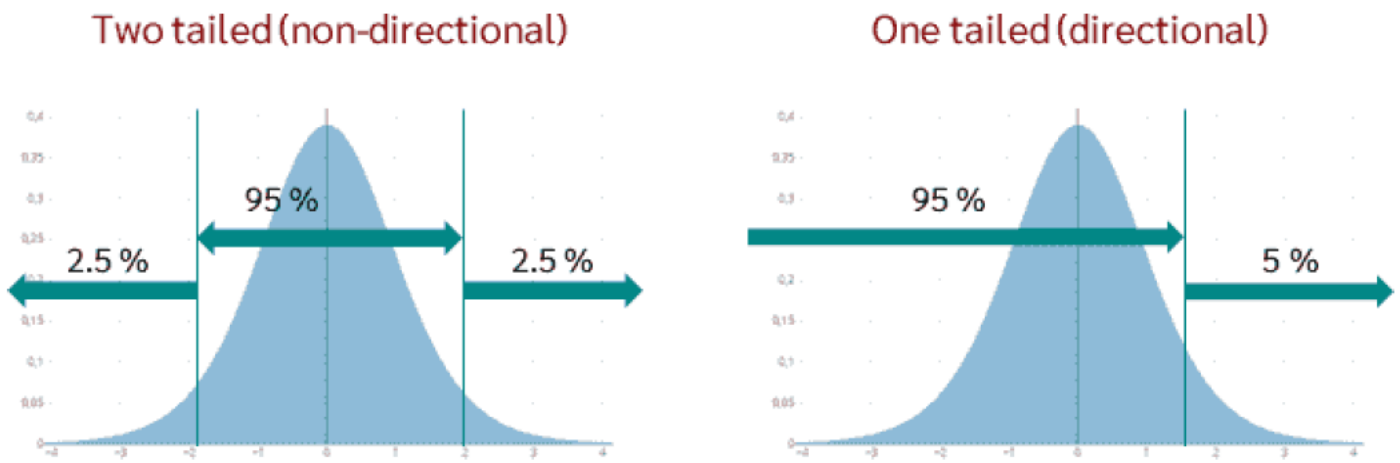
¿Qué tests existen?

- Para comparación de medias de variables continuas entre dos grupos.
  - → Ttest – requiere normalidad.
- Para comparar medias de variables continuas entre más de dos grupos.
  - → ANOVA (Análisis de Varianza) – requiere normalidad.
- Para evaluar asociación entre variable categóricas (comparando sus proporciones).
  - → Chi-cuadrado ($\chi^2$).
- Alternativa a $\chi^2$ para tablas pequeñas.
  - → Prueba exacta de Fisher.
- T-test no paramétrico (cuando no se cumple normalidad).
  - → Mann-Whitney U.
- ANOVA no paramétrico (cuando no se cumple normalidad).
  - → Test Kruskal-Wallis.

# Test de Hipótesis

T-Test.

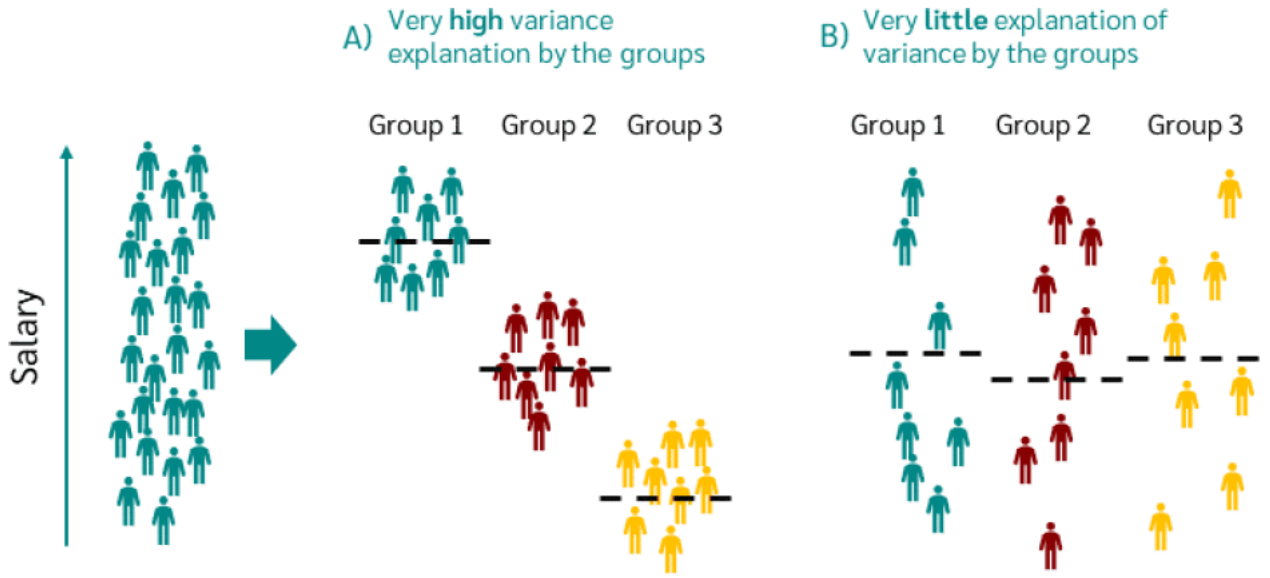
- Para comparación de medias de variables continuas entre dos grupos.



# Test de Hipótesis

ANOVA. Análisis de varianza.

- Para comparar medias de variables continuas entre más de dos grupos.



# Test de Hipótesis

Chi-cuadrado ($\chi^2$).

- Para evaluar asociación entre variable categóricas (comparando sus proporción.

| | Female | Male |
|---|---|---|
| Without graduation | 6 | 7 |
| College | 13 | 16 |
| Bachelor's degree | 16 | 15 |
| Master's degree | 8 | 11 |
| Total | **43** | **49** |

# Capacitación - Estadística Aplicada

- Tipos de variables.
- Estadística descriptiva.
- Asociación entre variables (correlaciones).
- Normalidad y funciones de distribución.
- Test de Hipótesis.



UNIVERSIDAD DE LOS LAGOS

UNIVERSIDAD DE LOS LAGOS

# Capacitación - Estadística Aplicada

Gracias!

**Pablo Herrera Gálvez / paherreragalvez@gmail.com**