UNIVERSIDAD DE LOS LAGOS

Capacitación - Estadística Aplicada

Sesión 2 – 19 diciembre 2024

Pablo Herrera Gálvez / paherreragalvez@gmail.com

Calendario

- 12 diciembre. Clase 1 (Estadística).
- 19 diciembre. Clase 2 (Estadística).
- *Pausa fiestas*.
- 2 enero. Clase 3 (R).
- 9 enero. Clase 4 (R).
- 16 enero. Clase 5 (R).
- 23 enero. Clase 6 (R).
- *Receso febrero*.
- 6 marzo. Clase 7 (Estadística - R).

Capacitación - Estadística Aplicada

- Recapitulación.
- Test de Hipótesis.
- Test de Normalidad.
- Tests estadísticos frecuentes.
- Regresión.



UNIVERSIDAD DE LOS LAGOS

Capacitación - Estadística Aplicada

- **Recapitulación.**
- Test de Hipótesis.
- Test de Normalidad.
- Tests estadísticos frecuentes.
- Regresión.



UNIVERSIDAD DE LOS LAGOS

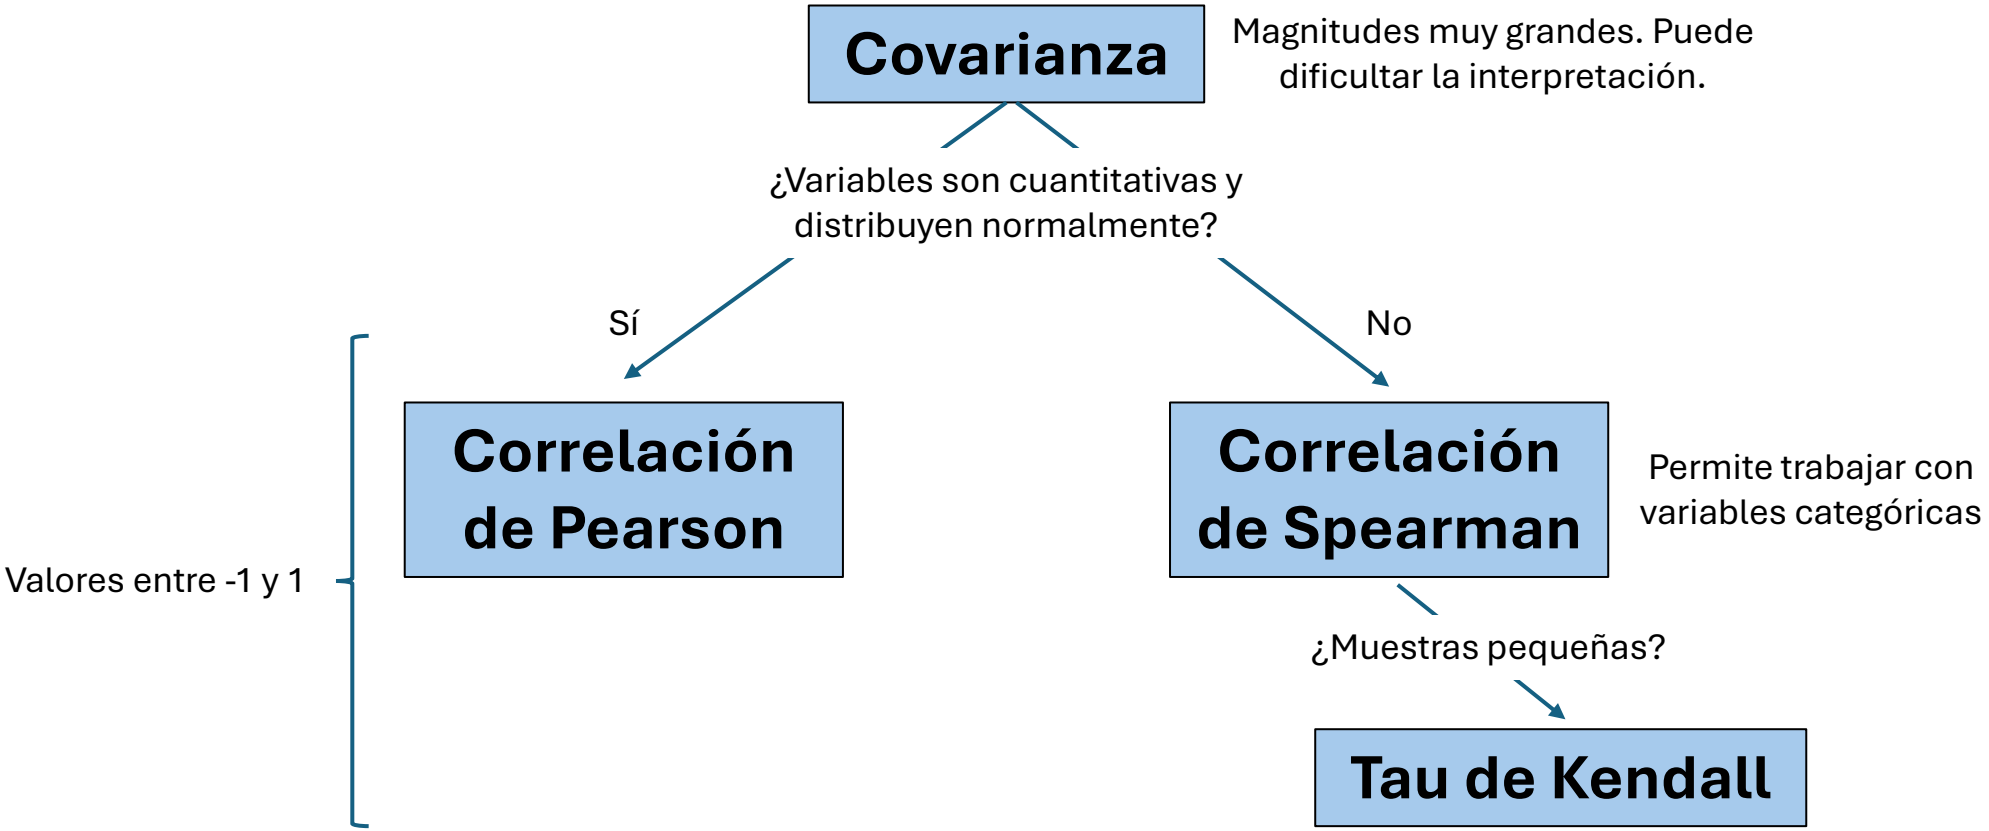
Recapitulación

Dudas/ideas de la semana pasada.

- Medidas de dispersión (varianza/desviación estándar), ¿muestrales o poblacionales? → Muestrales.
- Uso de Correlación de Pearson con índices construidos a partir de variables categóricas. → Sí, pues es una variable continua.

Recapitulación

Medidas de Asociación Lineal



Recapitulación

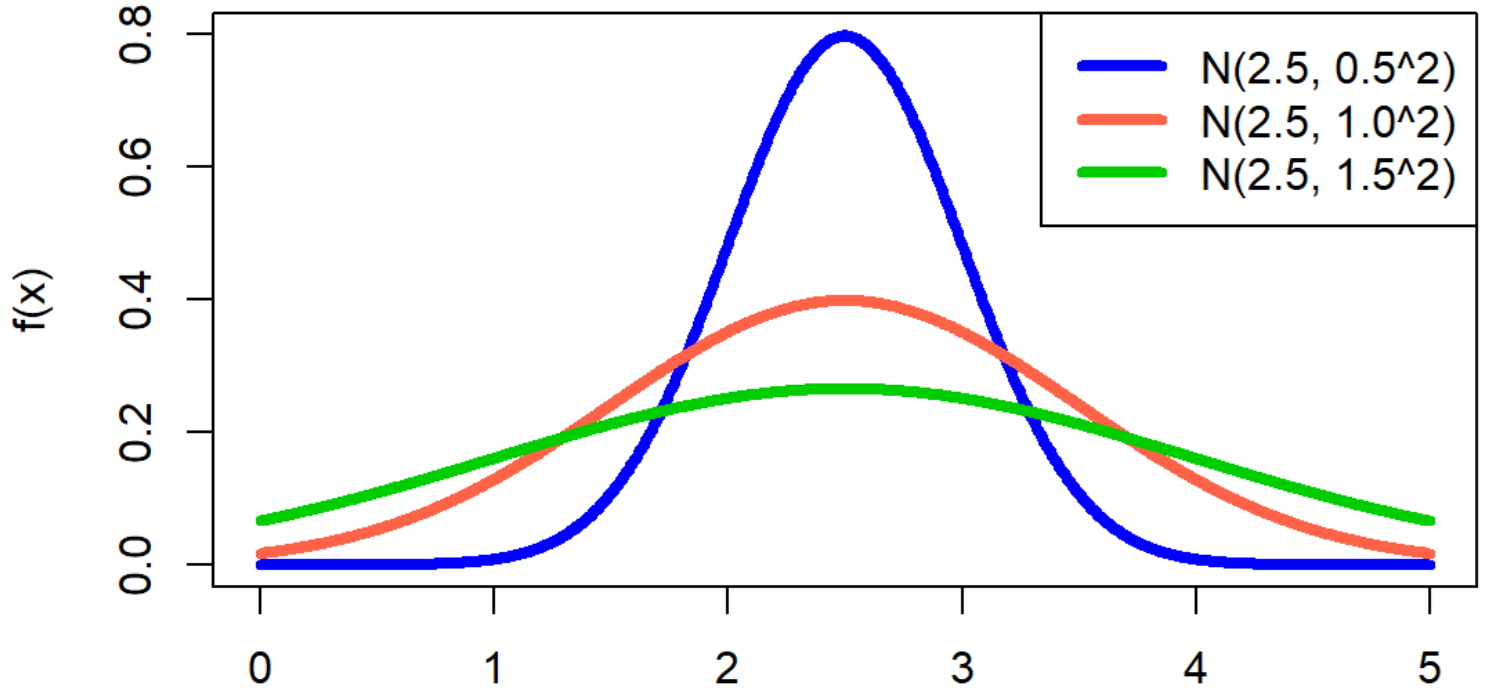
Normalidad.

- Una función de distribución de probabilidad (f.d.p.), se utiliza para describir la probabilidad de ocurrencia de un suceso (o rango).
- La suma de todas las probabilidades de una f.d.p. = 1 (o 100%).
- La distribución normal es una de las múltiples distribuciones que existen.
- Distribución simétrica (sobre la media). A mayor dispersión (varianza o desv. estándar), acumula más probabilidad en las colas (y menos prob. al centro).
- Notación: $N(\mu, \sigma^2)$.

Recapitulación

Normalidad.

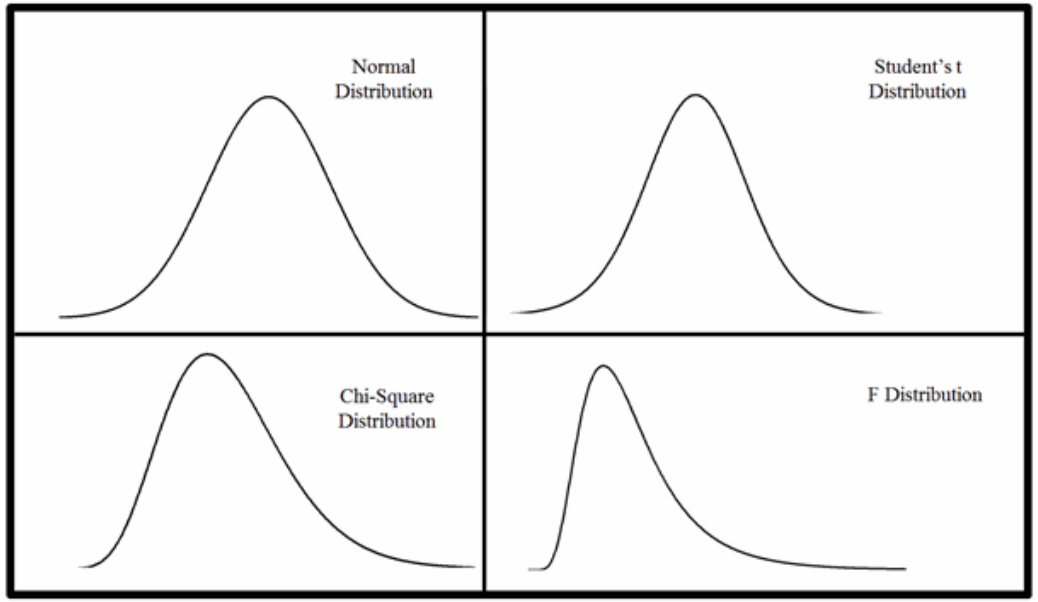
- Igual media, distintas varianzas.

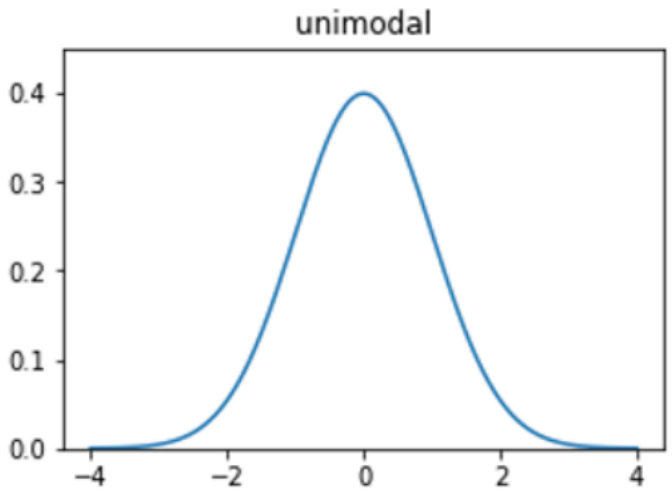


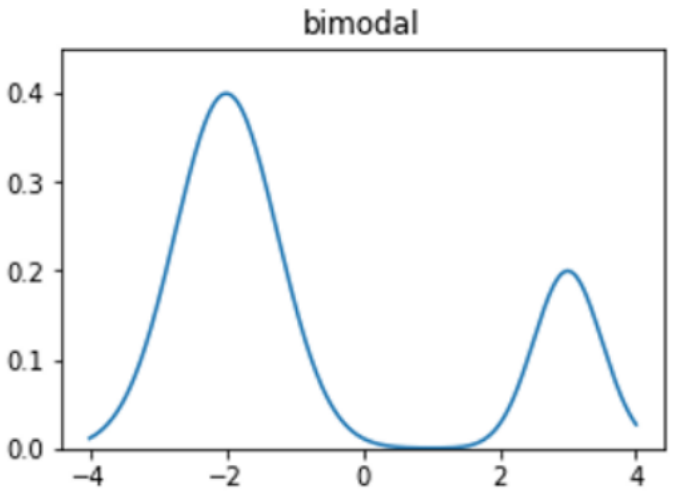
Recapitulación

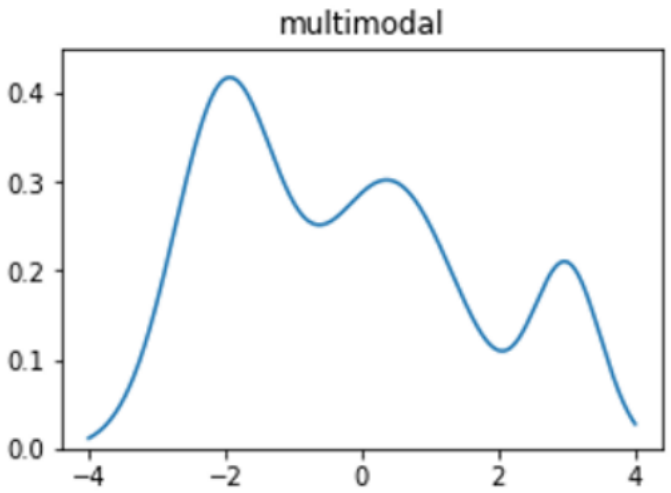
Normalidad.

- La distribución Normal no es la única que existe.









Recapitulación

Normalidad.

- Maneras de testear normalidad:
- Test de Kolmogorov-Smirnov, Test de Shapiro-Wilk, y el Test de Anderson Darling.
- Análisis gráfico.

Capacitación - Estadística Aplicada

- Recapitulación.
- **Test de Hipótesis.**
- Test de Normalidad.
- Tests estadísticos frecuentes.
- Regresión.

UNIVERSIDAD DE LOS LAGOS

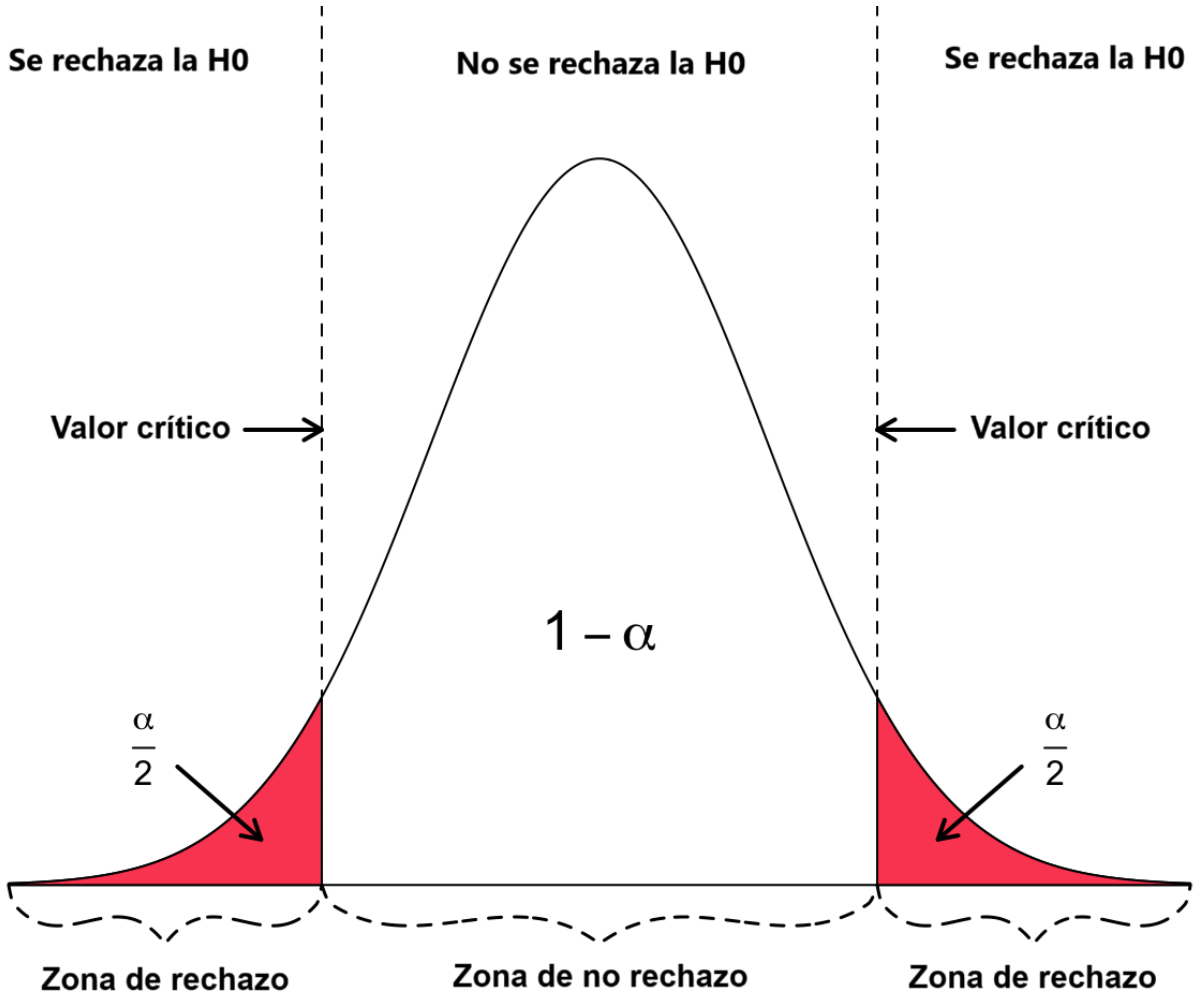
Test de Hipótesis

- Preguntas sí o no.
- Hipótesis nula (H_0). → H_0: E(Y) = 0 (ejemplo).
- Hipótesis alternativa (H_1). → H_1: E(Y) ≠ 0.
- Buscamos responder estas preguntas en base a la evidencia.
- Error muestral: dado que trabajamos con muestras, existe imprecisión o incertidumbre en la estimación. A menor tamaño de la muestra, mayor error muestral (sampling error).
- Valor de significancia (α) y valor de confianza (1-α).
- Intervalo de confianza.
- P-value.

Test de Hipótesis

- Dado que existe un error muestral, no podemos averiguar el valor poblacional exacto. Existe incertidumbre.
- Sin embargo en base a los datos de nuestra muestra, es posible estimar el valor poblacional con una probabilidad determinada.
- Nivel de significancia (α). Valores comúnmente utilizados son 0.1, 0.05 y 0.01 (10%, 5% y 1% respectivamente).
- Nivel de confianza (1-α). Valores comúnmente utilizados son 0.90, 0.95 y 0.99 (90%, 95 y 99% respectivamente).
- Intervalo de confianza: Aquellos valores para los cuales no rechazaría la hipótesis nula. En un (1-α)% de las estimaciones, capturamos el valor poblacional dentro del intervalo de confianza.

Test de Hipótesis

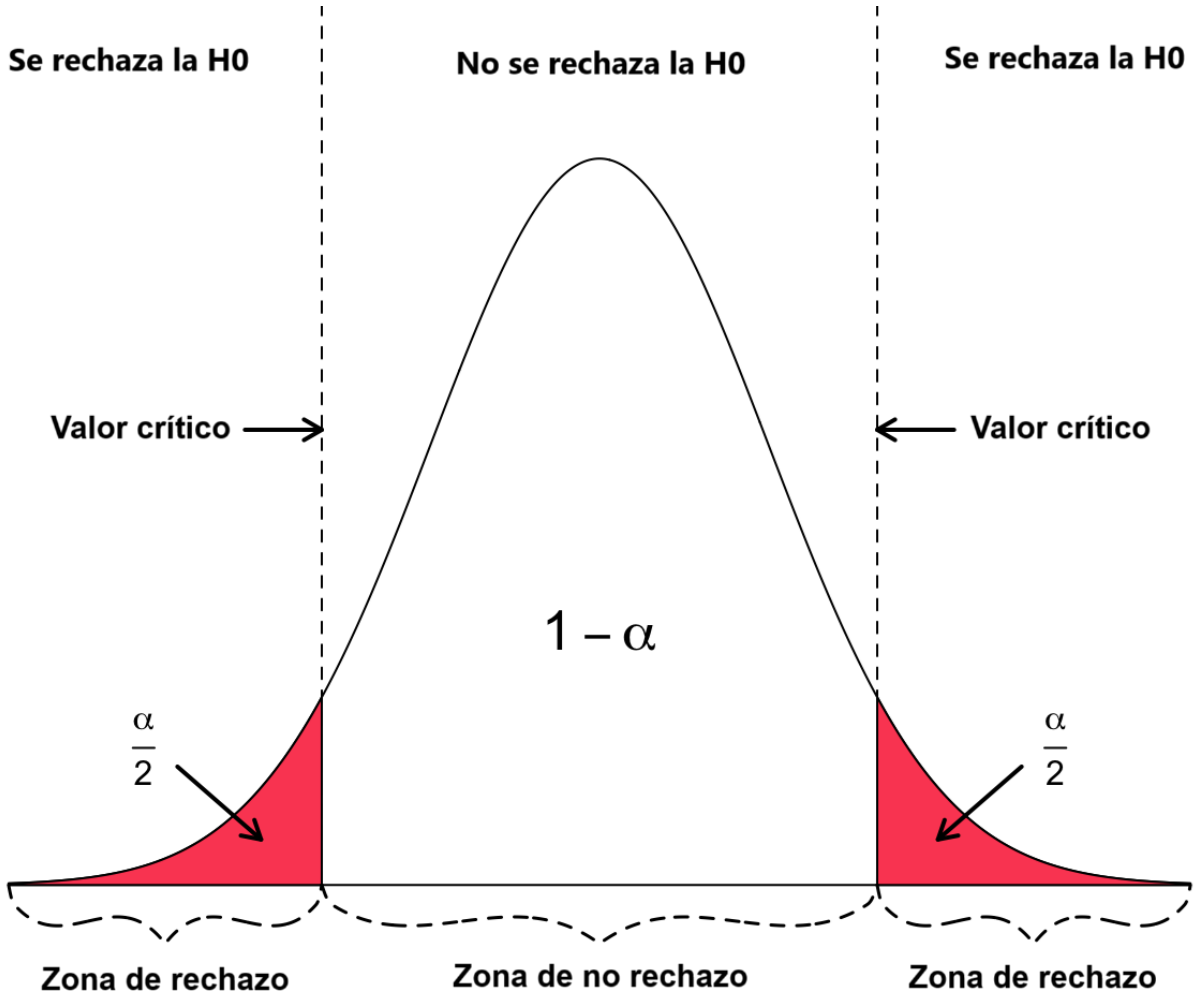


Test de Hipótesis

P-Value.

- Considerando la mencionada incertidumbre (producto del error muestral), el valor muestral (nuestra estimación) rara vez es exactamente igual al valor real (valor poblacional).
- Supongamos que el valor estimado con la muestra es de 0,5 (H_0: E(Y) = 0).
- El valor-P, representa cuál es la probabilidad de haber obtenido un resultado tan distinto a la hipótesis nula (H_0), como lo hemos hecho.
- Un p-value bajo quiere decir que, suponiendo que la H_0 es correcta, habría sido muy improbable obtener el valor estimado. En este caso se rechaza la hipótesis nula, aceptando la hipótesis alternativa.
- Por el contrario, si el p-value es alto, se dice que no se tiene evidencia suficiente para rechazar la hipótesis nula.

Test de Hipótesis



Test de Hipótesis

- Dada la incertidumbre asociada, existen dos conclusiones erróneas posibles: errores tipo I y II.

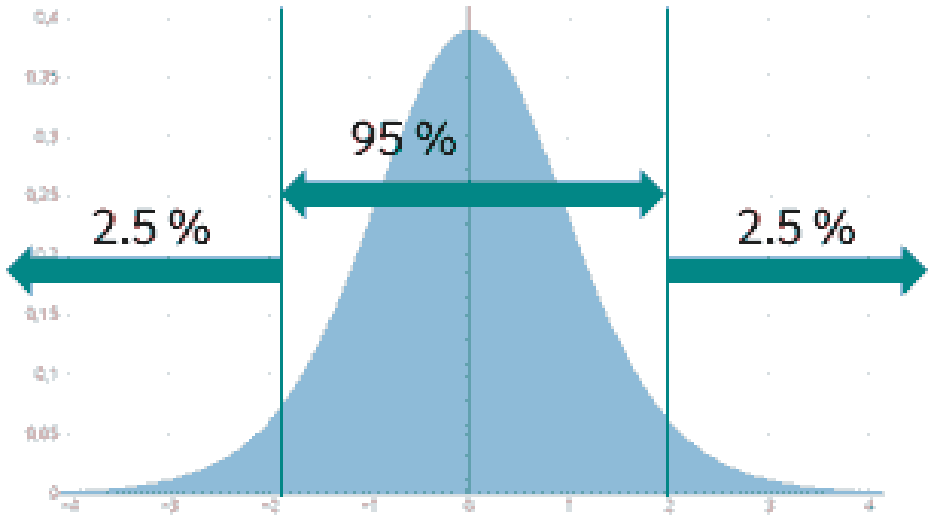
	La Hipótesis Nula es en realidad:	
Nuestra decisión c/r a la Hipótesis Nula:	**Verdadera**	**Falsa**
Aceptada	Correcto	Error Tipo II
Rechazada	Error Tipo I	Correcto

Test de Hipótesis

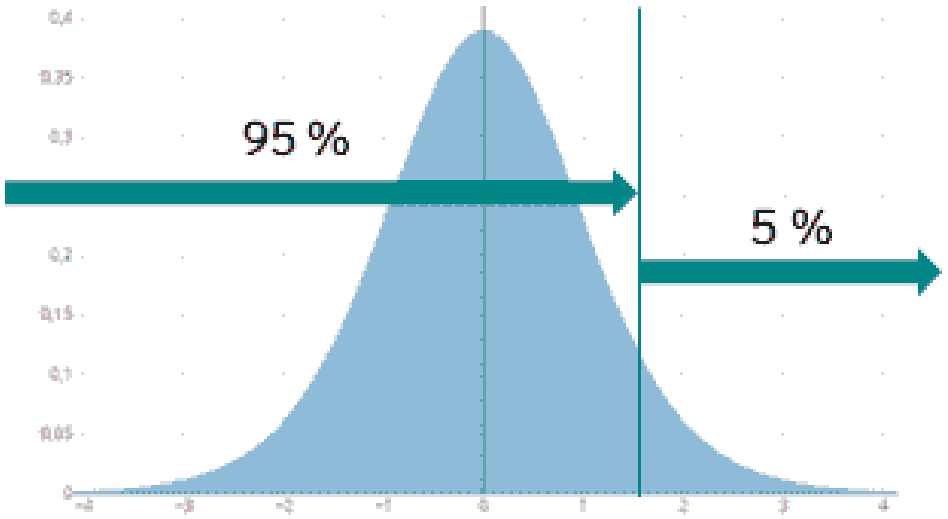
Ojo:

- Un test de medias, puede ser de dos colas (como el que acabamos de analizar), o bien de una sola cola.
- El test de dos colas se utiliza cuando la H0 define una igualdad. El test de una cola se utiliza cuando la H_0 define una desigualdad (< o >).

Two tailed (non-directional)



One tailed (directional)



Test de Hipótesis

Pasos para conducir un test de hipótesis:

- Definir las hipótesis nula y alternativa (H_0 y H_1).
- Definir el nivel de significancia (α) y el valor de confianza (1-α).
- Aplicar el test.
- Comparar el p-value con el nivel de significancia definido.

Supongamos lo siguiente:

- Se definió un α = 5% (0.05).
- Con la estimación de la media, se obtiene un p-value = 0.02.
- P-value ≤ α (0.02 ≤ 0.05). → Se rechaza la hipótesis nula.
- Video: https://www.youtube.com/watch?v=2fgQ_8AKhJY

Capacitación - Estadística Aplicada

- Recapitulación.
- Test de Hipótesis.
- **Test de Normalidad.**
- Tests estadísticos frecuentes.
- Regresión.



UNIVERSIDAD DE LOS LAGOS

Pruebas de Normalidad

- La normalidad es un requisito frecuente en las pruebas que estudiaremos en la siguiente sección. Por lo mismo es relevante testearla.

- Test de Kolmogorov-Smirnov → ($n < 2.000$).
- Test de Shapiro-Wilk ($n > 2.000$).
- Test de Anderson Darling (mayor relevancia de los datos extremos).
- Análisis gráfico (histograma y gráfico de cuantiles).

Pruebas de Normalidad

- Test de Kolmogorov-Smirnov.
- Test de Shapiro-Wilk.
- Test de Anderson Darling.

H_0: los datos se distribuyen como una normal.

- Video en inglés: https://www.youtube.com/watch?v=AVketBmpUTE

Ejemplo de resultados de Tests de Normalidad.

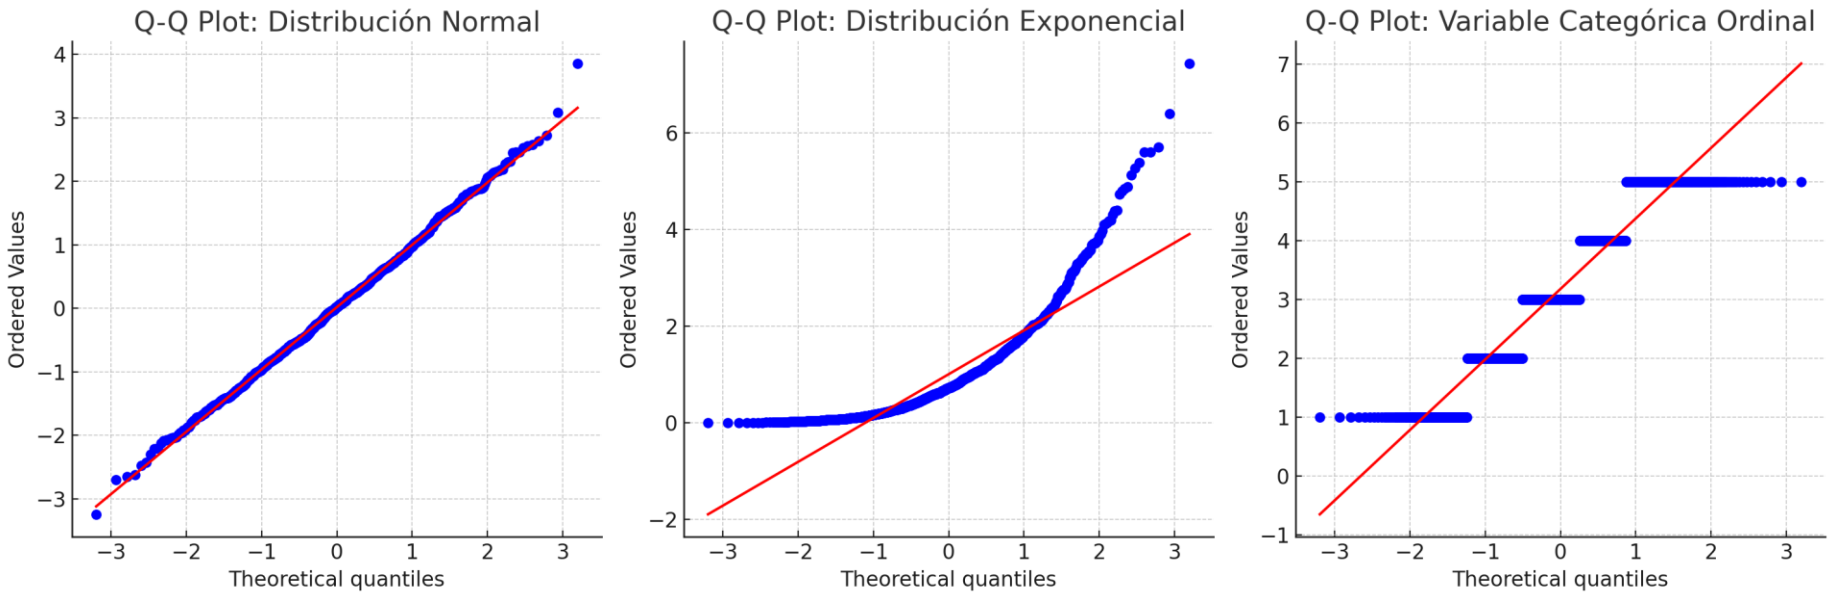
	Statistics	p-value
Kolmogorov-Smirnov	0.09	0.892
Shapiro-Wilk	0.98	0.862
Anderson-Darling	0.24	0.772

- Hipótesis nula testeada: *los datos se distribuyen como una normal*.
- P-values altos en los tres test (entre 0.7 y 0.9).
- Por lo tanto no se rechaza la hipótesis nula.
- Asumimos que *los datos se distribuyen como una normal*.

Pruebas de Normalidad

Análisis gráfico.

- Histograma.
- Gráfico de cuantiles o Q-Q plot.
- Video: https://www.youtube.com/watch?v=kx_o9rnI4DE



Capacitación - Estadística Aplicada

- Recapitulación.
- Test de Hipótesis.
- Test de Normalidad.
- **Tests estadísticos frecuentes.**
- Regresión.

UNIVERSIDAD DE LOS LAGOS

Tests frecuentes

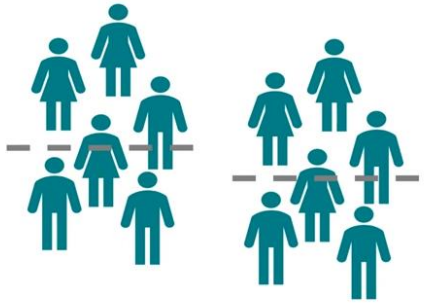
¿Qué tests existen?

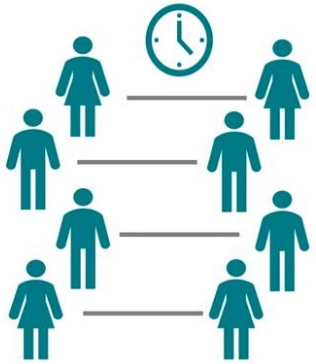
- Comparación de medias (de uno o dos grupos).
  - → **T-test.**
- Comparación de medias entre más de dos grupos.
  - → **ANOVA (Análisis de Varianza).**
- Evaluación de asociación entre variables categóricas (compara sus proporciones).
  - → **Chi-cuadrado (χ^2).**
- Alternativa a Chi-cuadrado (χ^2) para tablas pequeñas.
  - → **Prueba exacta de Fisher.**
- T-test no paramétrico (cuando no se cumple normalidad).
  - → **Mann-Whitney U.**
- ANOVA no paramétrico (cuando no se cumple normalidad).
  - → **Test Kruskal-Wallis.**

Tests frecuentes

T-test.







- Para comparación de medias de variables continuas.
- Existen tres tipos de T-test:
  - Una muestra.
  - Muestras independientes.
  - Muestras pareadas.
- Video: https://www.youtube.com/watch?v=qvey7do9TYU

Tests frecuentes

$$t = \frac{\bar{x} - \mu}{\frac{s}{\sqrt{n}}}$$

T-test (1) – una muestra:

- H_0: Media muestral = Valor de referencia.
- H_1: Media muestral ≠ Valor de referencia.
- Requisitos:
  - Una muestra y un valor de referencia.
  - Las observaciones son independientes entre ellas.
  - Variables cuantitativas y distribuidas como una normal.

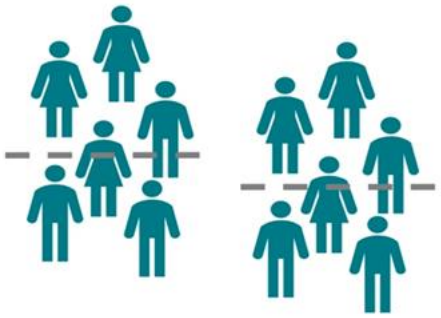


Tests frecuentes

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

T-test (2) – muestras independientes:

- H_0: Media muestra 1 = Media muestra 2.
- H_1: Media muestra 1 ≠ Media muestra 2.
- Requisitos:
  - Dos muestras independientes.
  - Variables cuantitativas y distribuidas como una normal.
  - Las varianzas de ambas muestras deben ser similares.
    - Test de Levine. Video: https://www.youtube.com/watch?v=x51GDTiPIfI
    - Si no hay iguales varianzas: Welch's t-test.

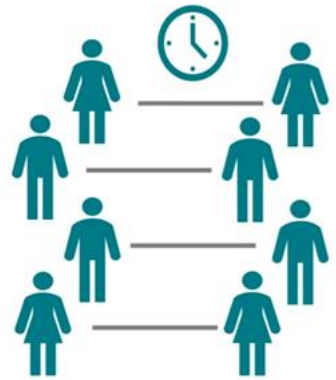


Tests frecuentes

$$t = \frac{\overline{x_d} - 0}{\frac{s}{\sqrt{n}}}$$

T-test (3) – muestras pareadas:

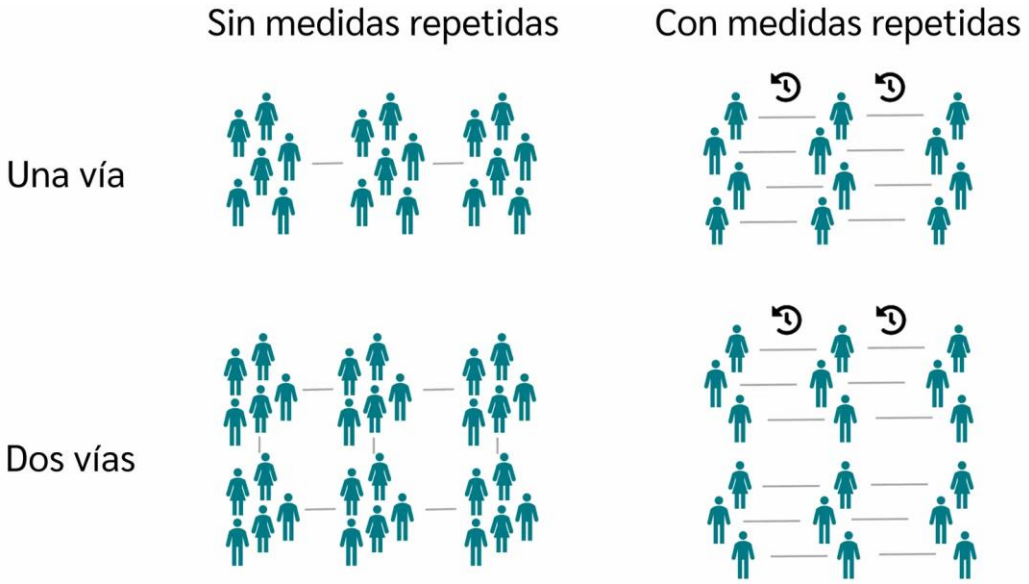
- H_0: Media de las diferencias entre los pares = 0.
- H_1: Media de las diferencias entre los pares ≠ 0.
- Requisitos:
  - Una muestra pareada.
  - Los pares deben ser independientes entre ellos.
  - Variables cuantitativas y las diferencias deben distribuir como una normal.



Tests frecuentes

ANOVA. Análisis de varianza.

- Mide el efecto de una variable categórica sobre una variable numérica. Comparar medias de variables continuas entre más de dos grupos.
- Existen algunas variantes:
  - 1 vía (1 dirección).
  - 2 vías (o 2 factores).
  - Uso o no mediciones repetidas.



Tests frecuentes

$$\frac{\textit{Varianza entre grupos}}{\textit{Varianza dentro de los grupos}} = F$$

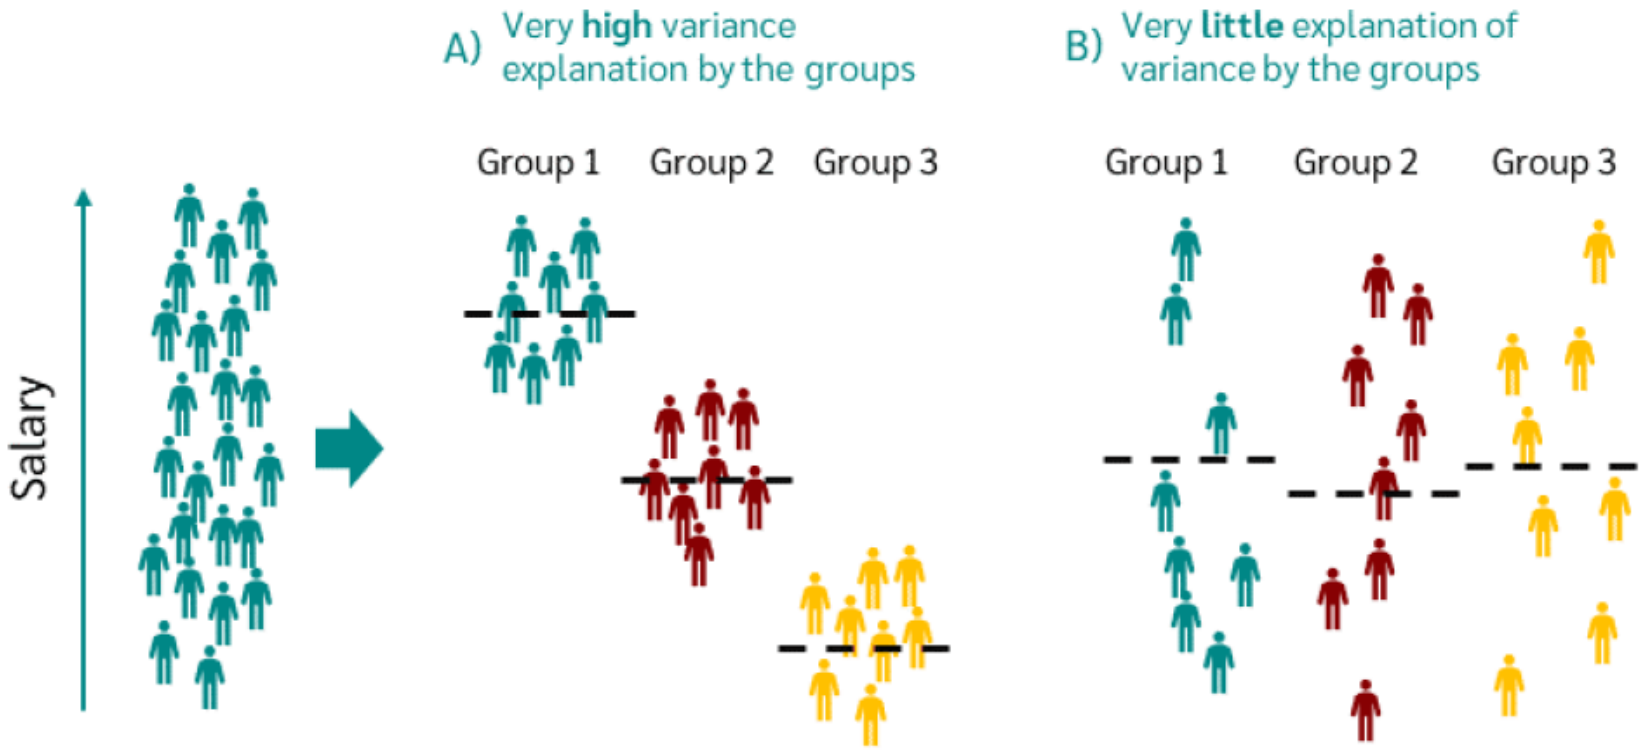
ANOVA. Análisis de varianza de 1 vía.

- H_0: Media muestra 1 = Media muestra 2 = … = Media muestra n.
- H_1: Al menos la media de una muestra es diferente al resto.
- Supuestos:
  - **Nivel de medida.** Variable independiente nominal, variable dependiente numérica/métrica.
  - **Independencia.** Las mediciones deben ser independientes entre los grupos (no se deben afectar).
  - **Normalidad** (pierde importancia a medida que aumenta la muestra).
    - ¿No se cumple? Kruskal-Wallis.
  - **Homogeneidad.** Las varianzas entre los grupos deben ser aproximadamente las mismas.
    - Test de Levene. → ¿No se cumple? ANOVA de Welch.
- Video 1 vía: https://www.youtube.com/watch?v=jW1Nfu0h0f0

Tests frecuentes

$$\frac{\textit{Varianza entre grupos}}{\textit{Varianza dentro de los grupos}} = F$$

ANOVA. Análisis de varianza de 1 vía.



Tests frecuentes

ANOVA. Análisis de varianza de 2 vías.

- H_0: No hay diferencias entre los grupos del primer factor.
  No hay diferencias entre los grupos del segundo factor.
  Un factor no influye en el efecto del otro factor.
- H_1: Hay una diferencia significativa entre los grupos del primer factor.
  Hay una diferencia significativa entre los grupos del segundo factor.
  Al menos un factor influye en el efecto del otro factor.
- Supuestos:
  - **Nivel de medida.** Variables independientes categóricas, variable dependiente numérica/métrica.
  - **Independencia.** Las mediciones deben ser independientes entre los grupos (no se deben afectar).
  - **Normalidad.**
  - Homogeneidad entre los grupos.

Tests frecuentes

ANOVA. Análisis de varianza de 2 vías.

- H_0: No hay diferencias entre los grupos del primer factor.
  No hay diferencias entre los grupos del segundo factor.
  Un factor no influye en el efecto del otro factor.
- H_1: Hay una diferencia significativa entre los grupos del primer factor.
  Hay una diferencia significativa entre los grupos del segundo factor.
  Al menos un factor influye en el efecto del otro factor.

	Suma de cuadrados de tipo III	df	Cuadrados medios	F	p	Eta_p^2
Medicamento	5	1	5	1.04	.324	0.06
Sexo	0.8	1	0.8	0.17	.689	0.01
Medicamento x Sexo	1.8	1	1.8	0.37	.55	0.02
Error	77.2	16	4.83			

- P-values altos (entre 0.3 y 0.7).
- Por lo tanto no se rechaza la hipótesis nula.
- Asumimos que no hay diferencias entre grupos.

- Video 2 vías: https://www.youtube.com/watch?v=S8-BlaYoJS4

Tests frecuentes

Chi-cuadrado (χ^2).

- Para evaluar asociación entre variable categóricas (comparando sus proporción.
- H_0: No existe relación entre las variables estudiadas.
- H_1: Existe relación entre las variables estudiadas.
- Supuestos:
  - Los valores esperados de cada celda son mayores a 5 (cuando esto no se cumple → Prueba exacta de Fisher).
  - Usa solo variables categóricas nominales. No ordinales.
  - Cuando se trabaja con variables categóricas ordinales: Correlación de Spearman, Mann-Whitney U o Test Kruskal-Wallis.

Tabla de frec. observadas.

	Mujeres	Hombres	Total	%
TVN	6	7	**13**	**14,1**
Mega	13	16	**29**	**31,5**
CHV	16	15	**31**	**33,7**
Canal 13	8	11	**19**	**20,7**
Total	**43**	**49**	**92**	**100**
%	**46,7**	**53,3**	**100**	

Tabla de frec. esperadas.

	Mujeres	Hombres	Total
TVN	6,08	6,92	**13**
Mega	13,55	15,45	**29**
CHV	14,49	16,51	**31**
Canal 13	8,88	10,12	**19**
Total	**43**	**49**	**92**

- Video: https://www.youtube.com/watch?v=G50EUu60E4w

Tests frecuentes

Prueba exacta de Fisher.

- Alternativa a Chi-cuadrado (χ^2) para muestras pequeñas.

Mann-Whitney U.

- T-test no paramétrico (cuando no se cumple normalidad).

Test Kruskal-Wallis.

- ANOVA no paramétrico (cuando no se cumple normalidad).

Capacitación - Estadística Aplicada

- Recapitulación.
- Test de Hipótesis.
- Test de Normalidad.
- Tests estadísticos frecuentes.
- **Regresión.**



UNIVERSIDAD DE LOS LAGOS

Análisis de regresión

- Nos permite estimar la pendiente de la línea de regresión poblacional. **Cuantificamos esta pendiente.**
- Es el efecto esperado sobre una variable dependiente (Y), ante un cambio unitario en una variable independiente (X).
- El objetivo último es buscar causalidad, pero por ahora buscaremos una línea recta que se ajuste a los datos observados.
- Supongamos que tenemos una muestra de colegios que incluye su desempeño en una prueba estandarizada y su ratio de Estudiantes/Profesores.
- Video 1 (Análisis de Regresión): https://www.youtube.com/watch?v=-JTKf-a1JpU
- Video 2 (Regresión Lineal Simple): https://www.youtube.com/watch?v=gPfgB4ew3RY

Análisis de regresión

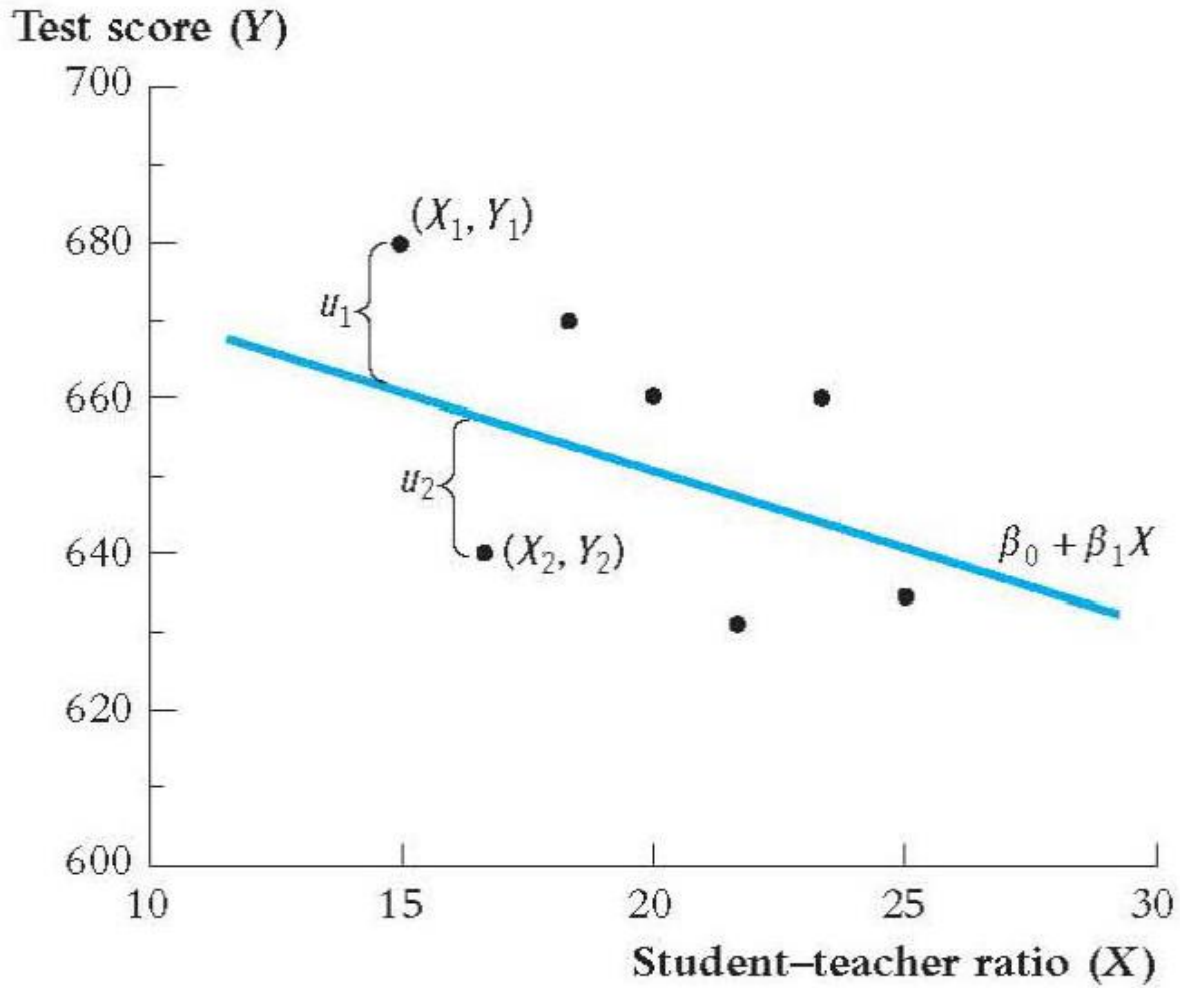
Modelo.

- Linea de regresión poblacional: TEST = β_0 + β_1*RATIO.
- β1 = △TEST / △RATIO = pendiente de la línea de reg. poblacional.

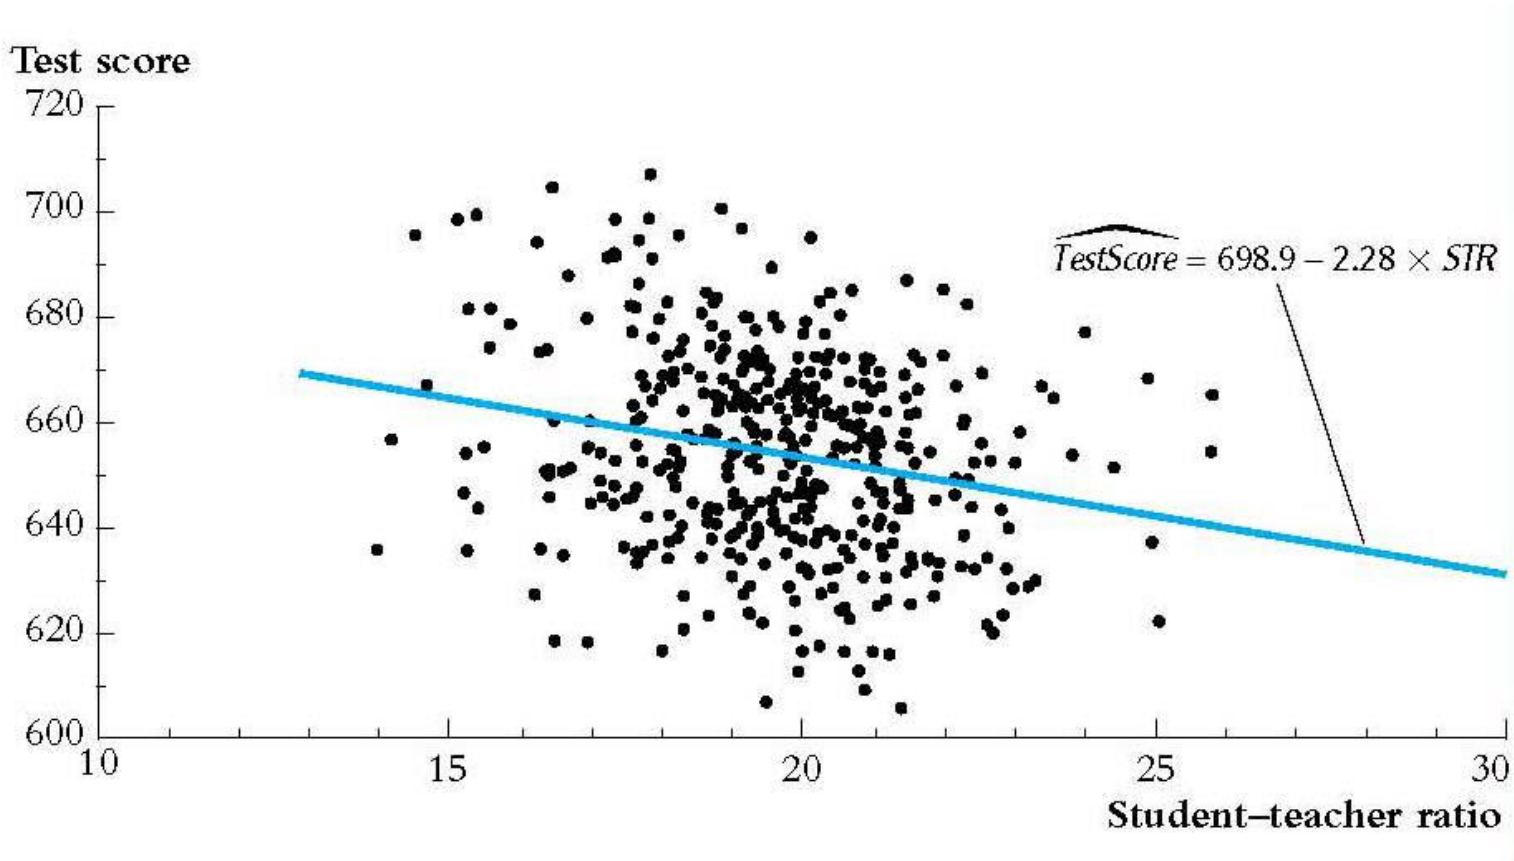
$$Y_i = \beta_0 + \beta_1 X_i + u_i,\ i = 1, \ldots, n$$

- X es la variable independiente o regressor.
- Y es la variable dependiente.
- β_0 intercepto.
- β_1 pendiente.
- u_i el error de regresión. Consiste en los factores omitidos.

Análisis de regresión



Análisis de regresión



Análisis de regresión

Estimación.

- Valor estimado de β_0 (intercepto): 698.9.
- **Valor estimado de β_1 (pendiente) : -2.28.**
- Linea de regresión estimada:

$$TEST = 698.9 \mathbf{- 2.28} * RATIO$$

- En promedio, un aumento de 1, en el Ratio Estudiantes/Profesores, tiene como resultado una disminución de 2.28 puntos en el la prueba estandarizada.

Análisis de regresión

```
regress testscr str, robust

Regression with robust standard errors                Number of obs =     420
                                                      F(  1,   418) =   19.26
                                                      Prob > F      =  0.0000
                                                      R-squared     =  0.0512
                                                      Root MSE      =  18.581

------------------------------------------------------------------------------
             |               Robust
    testscr |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
         str |  -2.279808   .5194892    -4.39   0.000    -3.300945   -1.258671
       _cons |   698.933   10.36436     67.44   0.000     678.5602    719.3057
------------------------------------------------------------------------------
```

- En regresión, la H_0 es que los coeficientes son 0. No hay relación entre la variable dependiente y la independiente.
- P-values bajos (ambos prácticamente 0).
- Por lo tanto se rechaza la hipótesis nula de que los coeficientes son cero.
- Aceptamos la H_1 de que cada coeficiente es distinto de 0.

Análisis de regresión

Interpretación.

$$TEST = 698.9 - \mathbf{2.28} * RATIO$$

- En promedio, un aumento unitario (de una unidad), en el Ratio Estudiantes/Profesores, tiene como resultado una disminución de 2.28 puntos en la prueba estandarizada.

Análisis de regresión

El R^2 como medida de ajuste.

- ESS. Suma explicada de los cuadrados.
- TSS. Suma total de los cuadrados.
- SSR. Suma residual de los cuadrados.

$$R^2 = \frac{ESS}{TSS}. \qquad R^2 = 1 - \frac{SSR}{TSS}.$$

$$ESS = \sum_{i=1}^{n} (\hat{Y}_i - \overline{Y})^2 \qquad TSS = \sum_{i=1}^{n} (Y_i - \overline{Y})^2. \qquad SSR = \sum_{i=1}^{n} \hat{u}_i^2.$$

Capacitación - Estadística Aplicada

- Recapitulación.
- Test de Hipótesis.
- Test de Normalidad.
- Tests estadísticos frecuentes.
- Regresión.



UNIVERSIDAD DE LOS LAGOS

Tareas

- Revisar primeras dos sesiones e identificar dudas (ver videos sugeridos).
- Hacer un mapa conceptual como el de la diapositiva 6, pero explicando los tests mencionados en la diapositiva 25.
  - Considerar sus supuestos y las variables que toleran.
- Descargar R Studio.
  - Video tutorial: https://www.youtube.com/watch?v=hbgzW3Cvda4
    - Instalar “R” y “R Studio”.

UNIVERSIDAD DE LOS LAGOS

Capacitación - Estadística Aplicada

Gracias!

Pablo Herrera Gálvez / paherreragalvez@gmail.com